Проверка соответствия центральных ViT-эмбеддингов человеческим оценкам цветового восприятия

Отчёт по эксперименту с Qwen2.5-VL и данными LUTCHI

1 Постановка гипотезы

Проверялась следующая гипотеза:

> Центральные visual embeddings модели Qwen2.5-VL содержат не только локальную информацию о физическом цвете центрального стимула, но и информацию об окружении. Поэтому линейно восстановленные из них координаты LCH должны быть похожи на человеческие оценки и изменяться при смене окружения сходным образом.

Эксперимент должен ответить на два вопроса:

1. похожи ли абсолютные значения
$$(\widehat{L}, \widehat{C}, \widehat{h})$$
на человеческие оценки
$$(L, C, h);$$
2. изменяются ли предсказанные значения при смене окружения так же, как человеческие оценки:
$$\Delta L_{\text{model}} \approx \Delta L_{\text{human}},$$
$$\Delta C_{\text{model}} \approx \Delta C_{\text{human}},$$
$$\Delta h_{\text{model}} \approx \Delta h_{\text{human}}.$$

2 Подготовка изображения и visual tokens

Исходное изображение имеет размер
$$224 \times 224$$
пикселя.

В конфигурации визуального энкодера Qwen2.5-VL были получены параметры:
$$\texttt{patch_size} = 14, \qquad \texttt{spatial_merge_size} = 2.$$

Сначала изображение разбивается на сетку исходных ViT-патчей:
$$\frac{224}{14} \times \frac{224}{14} = 16 \times 16.$$

Затем каждые 2×2 исходных патча объединяются в один итоговый visual token:

$$16 \times 16 \longrightarrow 8 \times 8.$$

В результате для одного изображения сохраняются

$$64$$

visual tokens, каждый из которых имеет размерность

$$3584.$$

Форма массива для одного изображения:

$$Z \in \mathbb{R}^{64 \times 3584}.$$

Один итоговый visual token соответствует области размером

$$14 \cdot 2 = 28$$

пикселей по каждой стороне, то есть области

$$28 \times 28.$$

2.1 Выбор центральных токенов

Центральный цветовой стимул имеет размер

$$80 \times 80$$

пикселей и расположен по центру изображения.
Его границы имеют координаты

$$72 \leq x < 152, \qquad 72 \leq y < 152.$$

Границы итоговой сетки visual tokens проходят через координаты

$$0,\ 28,\ 56,\ 84,\ 112,\ 140,\ 168,\ 196,\ 224.$$

Четыре токена в позициях

$$(3,3), \quad (3,4), \quad (4,3), \quad (4,4)$$

целиком находятся внутри центрального цветового стимула.
Их линейные индексы в сетке 8×8:

$$27, \quad 28, \quad 35, \quad 36.$$

Именно эти токены использовались далее.

Важно, что соответствующие им входные области не содержат пикселей окружения. Поэтому изменение их итоговых embedding-векторов при смене фона нельзя объяснить прямым попаданием фоновых пикселей внутрь патча.

При этом после прохождения visual transformer центральные токены могут получить информацию от остальных частей изображения через механизм attention. Именно наличие такой контекстной информации и проверяется в эксперименте.

3 Формирование признаков

Для каждого изображения извлекались четыре центральных токена:

$$Z_{\text{center}} = [z_{27}, z_{28}, z_{35}, z_{36}],$$

где

$$z_i \in \mathbb{R}^{3584}.$$

Четыре embedding-вектора объединялись в один признаковый вектор:

$$x = \text{vec}\,(Z_{\text{center}}).$$

Его размерность:

$$4 \cdot 3584 = 14336.$$

Таким образом, каждому изображению соответствовала пара

$$x_n \longrightarrow (L_n, C_n, h_n).$$

Всего было использовано

494

изображения. Пропущенных embedding-файлов не обнаружено.

4 Разбиение на train и test

Для проверки переноса на целый класс цветов использовалось не случайное разбиение.

Тестовая выборка состояла только из красных оттенков, а обучающая — из всех остальных оттенков.

Цвет считался красным, если его циклическое среднее значение h удовлетворяло условию

$$h_{\text{circ}} \in [330^\circ, 360^\circ) \cup [0^\circ, 30^\circ].$$

Циклическое среднее вычислялось через средние значения синуса и косинуса:

$$\overline{s} = \frac{1}{N} \sum_{i=1}^{N} \sin h_i,$$

$$\overline{c} = \frac{1}{N} \sum_{i=1}^{N} \cos h_i,$$

$$h_{\text{circ}} = \operatorname{atan2}\left(\overline{s}, \overline{c}\right).$$

Это необходимо, поскольку обычное арифметическое среднее некорректно работает около границы $0°/360°$.

Например, среднее между

$$355° \quad \text{и} \quad 5°$$

должно находиться около $0°$, а не около $180°$.

В результате было получено:

Table 1: Состав обучающей и тестовой выборок.

Выборка	Число изображений	Число цветовых групп
Train: некрасные оттенки	374	149
Test: красные оттенки	120	45

Красные оттенки полностью отсутствовали в обучающей выборке. Поэтому тестирование проверяет способность линейного проектора переносить зависимость на невиданный диапазон цветового тона.

5 Линейный проектор

В качестве проектора использовалась Ridge-регрессия.

Для L и C обучались отображения

$$\widehat{L} = w_L^{\mathsf{T}} x + b_L,$$

$$\widehat{C} = w_C^{\mathsf{T}} x + b_C.$$

Перед обучением признаки стандартизировались только по обучающей выборке.

Использовался коэффициент регуляризации

$$\alpha = 100.$$

Регуляризация необходима из-за высокой размерности признаков:

$$14336$$

признаков при

$$374$$

обучающих изображениях.

5.1 Циклическое представление цветового тона

Непосредственное предсказание числового значения h оказалось некорректным, поскольку цветовой тон является циклической величиной:

$$0^\circ \equiv 360^\circ.$$

Например, оттенки

$$5^\circ \quad \text{и} \quad 355^\circ$$

различаются только на 10°, хотя обычная числовая разность составляет 350°.

Поэтому вместо самого угла использовались две целевые переменные:

$$s = \sin h, \qquad c = \cos h.$$

Обучался проектор

$$x \longrightarrow (\widehat{s}, \widehat{c}).$$

После предсказания угол восстанавливался по формуле

$$\widehat{h} = \operatorname{atan2}(\widehat{s}, \widehat{c}).$$

Предсказанная пара дополнительно нормировалась на единичную окружность:

$$(\widehat{s}, \widehat{c}) \leftarrow \frac{(\widehat{s}, \widehat{c})}{\sqrt{\widehat{s}^2 + \widehat{c}^2}}.$$

6 Метрики качества

Для L и C использовались средняя абсолютная ошибка и коэффициент детерминации.

Средняя абсолютная ошибка:

$$\mathrm{MAE} = \frac{1}{N} \sum_{i=1}^{N} |y_i - \widehat{y}_i|.$$

Чем меньше MAE, тем ближе предсказания к человеческим оценкам.

Коэффициент детерминации:

$$R^2 = 1 - \frac{\sum_i (y_i - \widehat{y}_i)^2}{\sum_i (y_i - \overline{y})^2}.$$

Значение R^2, близкое к единице, означает, что модель хорошо объясняет изменчивость целевой величины.

Для h использовалась минимальная циклическая ошибка:

$$e_h = \left| \left(\widehat{h} - h + 180^\circ \right) \bmod 360^\circ - 180^\circ \right|.$$

Также вычислялся средний косинус угловой ошибки:

$$S_{\cos} = \frac{1}{N} \sum_{i=1}^{N} \cos\left(\widehat{h}_i - h_i\right).$$

Интерпретация:

$$S_{\cos} = 1$$

соответствует идеальному совпадению,

$$S_{\cos} = 0$$

соответствует средней ошибке около $90°$, а

$$S_{\cos} = -1$$

означает предсказание противоположного оттенка.

7 Абсолютные значения LCH

Результаты восстановления абсолютных человеческих оценок приведены в таблице 2.

Table 2: Качество восстановления абсолютных человеческих оценок по четырём центральным visual tokens.

Компонента	Train MAE	Train R^2	Test MAE	Test R^2
L	0.776	0.996	2.383	0.966
C	1.003	0.993	3.984	0.901

Для циклического цветового тона были получены результаты:

Table 3: Качество циклического восстановления цветового тона.

Выборка	Circular MAE	Mean cosine score
Train	$3.18°$	0.994
Test: красные оттенки	$14.15°$	0.947

Полученные результаты показывают, что проектор, обученный без красных оттенков, хорошо переносится на красную область цветового пространства.

Особенно высокое качество получено для светлоты:

$$\mathrm{MAE}(L) = 2.38, \qquad R^2(L) = 0.966.$$

Для красочности качество ниже, но остаётся высоким:

$$\mathrm{MAE}(C) = 3.98, \qquad R^2(C) = 0.901.$$

После перехода к циклическому представлению ошибка цветового тона уменьшилась до

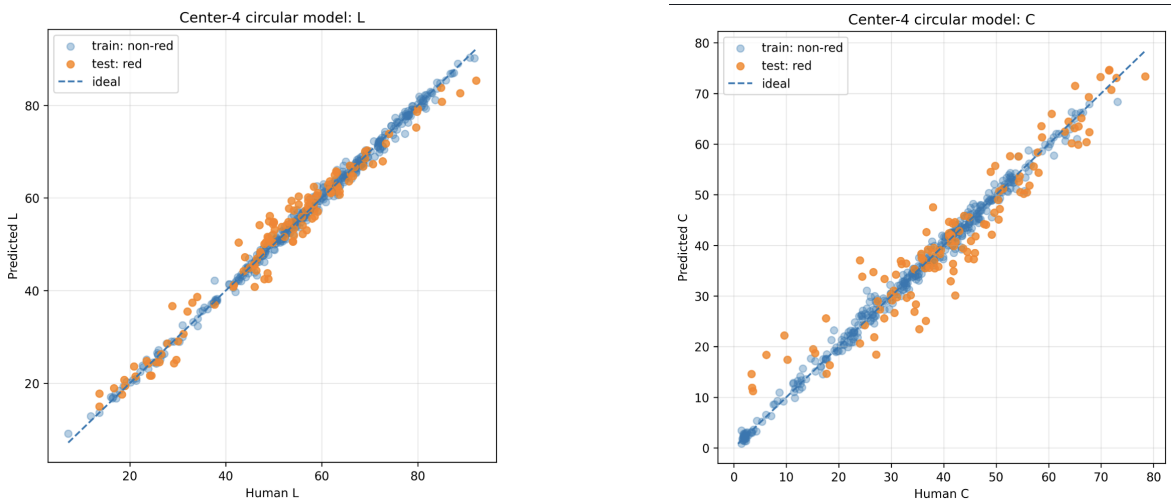
$$14.15^\circ.$$

В предыдущей постановке, где h рассматривался как обычное число, циклическая тестовая ошибка составляла приблизительно

$$62.23^\circ.$$

Следовательно, плохой предыдущий результат был в значительной степени связан с неправильным представлением угловой целевой переменной, а не с отсутствием информации о тоне в центральных embeddings.

7.1 Графики истинных и предсказанных значений



(a) Светлота L.

(b) Красочность C.

Figure 1: Истинные человеческие оценки и значения, восстановленные из четырёх центральных visual tokens.

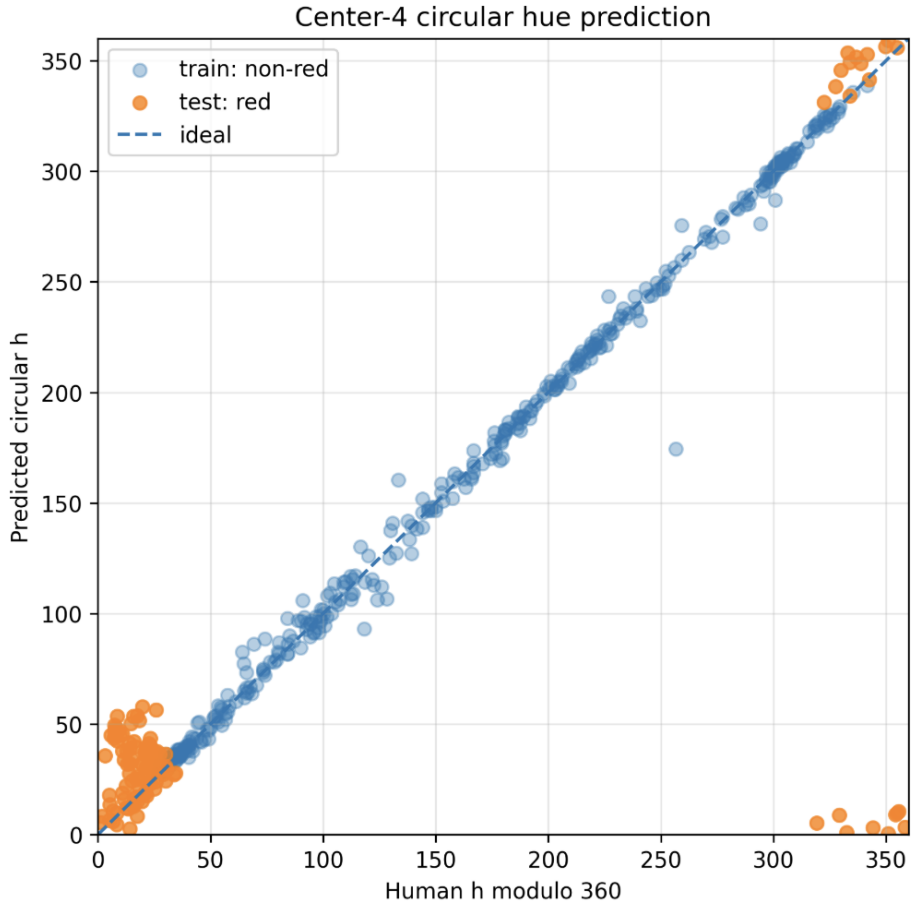


Figure 2: Циклическое восстановление цветового тона h. Красные тестовые точки находятся около границы $0°/360°$, поэтому визуально образуют две группы, хотя на цветовом круге они близки.

На рисунке 1 тестовые точки для L в основном расположены близко к идеальной диагонали. Для C наблюдается больший разброс, однако общая зависимость сохраняется.

Рисунок 2 необходимо интерпретировать с учётом цикличности. Например, пара

$$h_{\text{human}} = 358°, \qquad h_{\text{model}} = 2°$$

визуально находится далеко от диагонали на обычном декартовом графике, но фактическая циклическая ошибка составляет всего

$$4°.$$

8 Проверка реакции на изменение окружения

Высокое качество абсолютного восстановления LCH ещё не доказывает, что модель воспроизводит человеческий эффект окружения.

Поэтому отдельно сравнивались изменения оценок для одного и того же центрального цвета при разных окружениях.

Для каждой пары окружений s_1 и s_2 вычислялись человеческие сдвиги:

$$\Delta L_{\text{human}} = L_{s_2} - L_{s_1},$$

$$\Delta C_{\text{human}} = C_{s_2} - C_{s_1}.$$

Модельные сдвиги вычислялись аналогично:

$$\Delta L_{\text{model}} = \widehat{L}_{s_2} - \widehat{L}_{s_1},$$

$$\Delta C_{\text{model}} = \widehat{C}_{s_2} - \widehat{C}_{s_1}.$$

Для цветового тона использовалась минимальная знаковая циклическая разность:

$$\Delta h = (h_{s_2} - h_{s_1} + 180^\circ) \bmod 360^\circ - 180^\circ.$$

Таким образом, например, переход

$$355^\circ \longrightarrow 5^\circ$$

задаётся сдвигом

$$+10^\circ,$$

а не -350°.

8.1 Показатели сравнения сдвигов

Для каждого компонента вычислялись:

- MAE между человеческими и модельными сдвигами;
- коэффициент корреляции Пирсона r;
- доля совпадения знака изменения.

Совпадение знака означает, что человек и модель изменили оценку в одном направлении. Например:

$$\Delta L_{\text{human}} > 0, \qquad \Delta L_{\text{model}} > 0$$

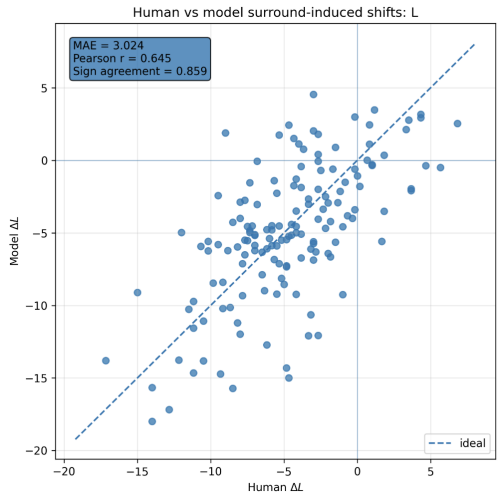
означает, что и человек, и модель оценили стимул как более светлый после смены окружения.

Результаты приведены в таблице 4.

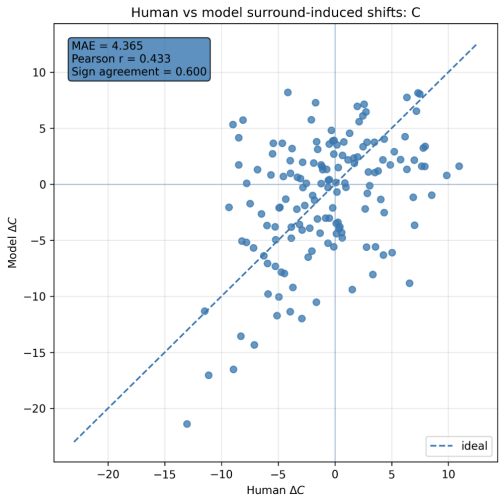
Table 4: Сходство человеческих и модельных изменений LCH при смене окружения.

Компонента	MAE сдвига	Pearson r	Совпадение знака
ΔL	3.024	0.645	85.9%
ΔC	4.365	0.433	60.0%
Δh	7.115°	0.194	58.5%

8.2 Графики человеческих и модельных сдвигов



(a) Изменения светлоты ΔL.



(b) Изменения красочности ΔC.

Figure 3: Человеческие и модельные изменения при смене окружения. Пунктир соответствует идеальному совпадению сдвигов.

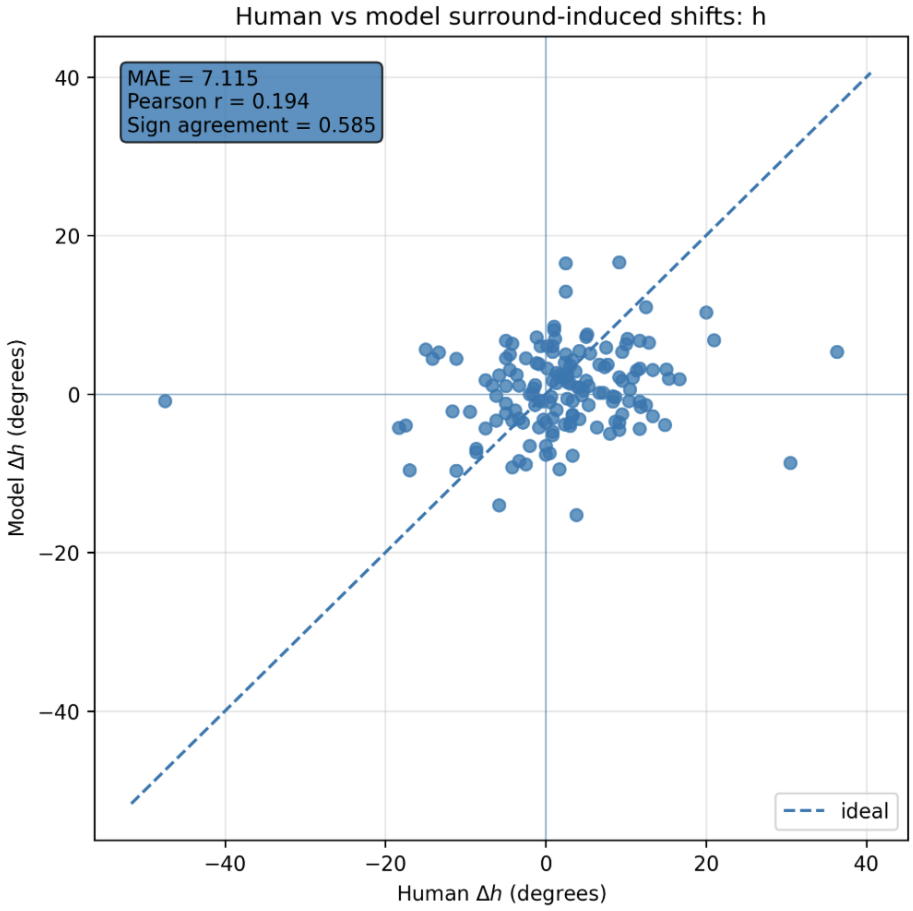


Figure 4: Человеческие и модельные циклические изменения цветового тона Δh.

9 Интерпретация результатов

9.1 Светлота

Для светлоты получена корреляция

$$r = 0.645.$$

Это указывает на заметную положительную связь между человеческими и модельными изменениями.

Совпадение направления составило

$$85.9\%.$$

Следовательно, если человек при смене окружения оценивал центральный цвет как более светлый или более тёмный, модель в большинстве случаев изменяла предсказание в том же направлении.

Средняя ошибка сдвига:

$$\mathrm{MAE}(\Delta L) = 3.024.$$

Таким образом, для светлоты гипотеза подтверждается наиболее уверенно.

Центральные embeddings не только позволяют восстановить абсолютное значение L, но и изменяются при смене окружения сходным с человеческим восприятием образом.

При этом точки не располагаются строго на идеальной диагонали. Модель лучше воспроизводит направление эффекта, чем его точную величину.

9.2 Красочность

Для красочности получено:

$$r = 0.433,$$

$$\mathrm{MAE}(\Delta C) = 4.365,$$

$$\text{совпадение знака} = 60.0\%.$$

Положительная зависимость сохраняется, но она слабее, чем для светлоты.

Модель частично чувствует изменения красочности, вызванные окружением, однако предсказания имеют значительный разброс.

Для C гипотеза подтверждается частично: в central embeddings присутствует информация об эффекте окружения, но она не полностью соответствует человеческим оценкам.

9.3 Цветовой тон

Для цветового тона получено:

$$r = 0.194,$$

$$\mathrm{MAE}(\Delta h) = 7.115^\circ,$$

$$\text{совпадение знака} = 58.5\%.$$

Корреляция является слабой.

На рисунке 4 модельные сдвиги в основном сосредоточены около нуля, даже когда человеческие изменения имеют большую величину.

Это может означать, что проектор сглаживает влияние окружения на цветовой тон. Центральные embeddings позволяют достаточно хорошо восстановить абсолютный h, но относительные изменения оттенка при смене окружения воспроизводятся хуже.

Таким образом, для h гипотеза подтверждается слабо.

10 Основные выводы

По результатам эксперимента можно сделать следующие выводы.

1. Четыре центральных visual tokens соответствуют областям, полностью находящимся внутри центрального цветового стимула.
2. Эти токены при этом содержат информацию, достаточную для восстановления человеческих координат LCH.
3. Проектор, обученный без красных оттенков, хорошо переносится на целый невиданный класс красных цветов.
4. Для светлоты получено наиболее высокое качество:

$$\mathrm{MAE}(L) = 2.38, \qquad R^2(L) = 0.966.$$

5. Для красочности также сохраняется высокая зависимость:

$$\mathrm{MAE}(C) = 3.98, \qquad R^2(C) = 0.901.$$

6. После перехода к циклическому представлению $(\sin h, \cos h)$ тестовая ошибка оттенка уменьшилась до

$$14.15^\circ.$$

7. Изменения светлоты при смене окружения воспроизводятся моделью достаточно хорошо:

$$r = 0.645, \qquad \text{совпадение знака} = 85.9\%.$$

8. Изменения красочности воспроизводятся частично:

$$r = 0.433, \qquad \text{совпадение знака} = 60.0\%.$$

9. Изменения цветового тона воспроизводятся слабо:

$$r = 0.194, \qquad \text{совпадение знака} = 58.5\%.$$

Итоговая гипотеза подтверждается частично.

Центральные embeddings Qwen2.5-VL действительно содержат контекстную информацию об окружении. Наиболее близкое к человеческому поведение наблюдается для светлоты. Для красочности соответствие слабее, а для изменений цветового тона остаётся низким.

11 Ограничения текущего эксперимента

При интерпретации результатов необходимо учитывать несколько ограничений.

1. Для каждого цвета сравнивались все доступные пары окружений. Поэтому несколько пар, построенных для одного $\text{color}_i d, .$

2. Класс красных цветов определялся по циклическому среднему человеческого значения h. Более строгим вариантом было бы использовать физические координаты центрального стимула или заранее выбранное референсное окружение.

3. Размерность признакового вектора составляет

$$14336,$$

тогда как обучающих изображений только

$$374.$$

Поэтому, несмотря на Ridge-регуляризацию, остаётся риск переобучения.

4. Хорошее восстановление абсолютных LCH не обязательно означает точное воспроизведение механизма человеческого восприятия. Линейный проектор может использовать корреляции, присутствующие в датасете.

5. Наличие информации об окружении в центральных токенах согласуется с влиянием attention, но текущий эксперимент сам по себе не является прямым причинным доказательством того, через какой конкретно слой или attention-head эта информация передаётся.