Анализ представлений цвета с учетом адаптирующего поля в мультимодальных больших языковых моделях

Рудоманова М.А.[1,2] , Лобарев Г.Р.[1,2]

[1] Институт проблем передачи информации им. А.А. Харкевича РАН
[2] Московский физико-технический институт (национальный исследовательский университет)
rudomanova.ma@phystech.edu, lobarev.gr@iitp.ru

Аннотация Цвет является важной составляющей визуальной информации, обрабатываемой современными мультимодальными большими языковыми моделями, однако остаётся неясным, отражают ли их внутренние представления контекстно-зависимый внешний вид цвета, характерный для человеческого восприятия. В отличие от задач распознавания цвета, в данной работе исследуется изменение представления одного и того же физического цветового стимула при изменении условий наблюдения. Предлагается метод анализа цветового восприятия мультимодальной модели, основанный на прямом сопоставлении изменений её внутренних представлений с психофизическими оценками человека из набора LUTCHI. Исследование проводится для Qwen2.5-VL-7B и включает представления визуального энкодера, скрытые состояния языковой части и явные численные ответы модели. Наиболее выраженный результат получен для полноты цвета при переходе между серым и белым адаптирующим окружением: изменения визуальных представлений позволяют предсказывать человеческие изменения с корреляцией Пирсона $r = 0.782$. Таким образом, контекстно-зависимые изменения человеческого восприятия цвета частично представлены во внутренних состояниях мультимодальной модели, хотя эта информация значительно слабее проявляется в её конечных численных ответах.

Ключевые слова: цветовое восприятие, внешний вид цвета, внутренние представления, мультимодальные языковые модели, LUTCHI

1 Введение

Современные мультимодальные большие языковые модели применяются для анализа изображений, документов и других визуальных данных, где информация о цвете может иметь существенное значение. При этом способность модели правильно распознавать цвет ещё не означает, что её внутреннее представление отражает особенности человеческого цветового восприятия. В частности, внешний вид одного и того же физического цвета у человека зависит от условий наблюдения: изменение фона, окружения и уровня

адаптации может приводить к изменению воспринимаемой светлоты, полноты цвета и цветового тона даже при неизменных физических характеристиках самого стимула [2]. Поэтому для исследования цветового восприятия мультимодальных моделей важно анализировать не только абсолютную информацию о цвете, но и чувствительность внутренних представлений к визуальному контексту. Такой анализ важен для понимания того, какая информация о цветовом контексте доступна модели до генерации ответа; в перспективе он может служить основой для разработки нейросетевых метрик цветоразличения и других моделей, ориентированных на человеческие оценки. При этом наличие такой информации само по себе не означает сходства механизмов обработки цвета в модели и человеческой зрительной системе.

Однако возможность восстановить характеристики отдельного цветового стимула не показывает, отражает ли модель изменение его внешнего вида при изменении визуального окружения. Насколько нам известно, контекстнозависимые изменения внутренних представлений мультимодальных моделей ранее напрямую не сопоставлялись с психофизическими измерениями изменения внешнего вида одного и того же физического цвета.

В настоящей работе предлагается рассматривать мультимодальную модель как аналитическую систему, а термин «вычислительный колориметр» использовать только для обозначения модели, чьи внутренние представления сопоставляются с психофизическими данными. Цель работы — исследовать изменение её внутренних представлений при контролируемом изменении условий наблюдения. Для этого используются психофизические данные LUTCHI [7,8,9], содержащие человеческие оценки светлоты, полноты цвета и цветового тона одних и тех же физических цветов при различных сочетаниях фона и окружения. Для каждого физического цвета сопоставляются изменения человеческих оценок и внутренних представлений Qwen2.5-VL-7B. Анализируются представления визуального энкодера, скрытые состояния языковой части перед генерацией и явные численные ответы модели. Дополнительно для одного из переходов проводится сравнение с моделью цветового восприятия CAM16 [4].

2 Предшествующие исследования

2.1 Цвет в мультимодальных моделях

Большинство исследований способности мультимодальных моделей работать с цветом основано на анализе их конечных ответов. Например, ColorBench включает задачи на распознавание и сравнение цветов, рассуждение о цвете и устойчивость к изменениям цветовых характеристик изображения [5]. Такие тесты характеризуют итоговое поведение модели, однако не позволяют определить, какая информация о цвете доступна во внутренних представлениях до генерации ответа.

Другой подход состоит в непосредственном анализе внутренних состояний модели. В работе [6] исследовалось линейное декодирование харак-

теристик воспринимаемого цвета из внутренних представлений мультимодальных больших языковых моделей. Полученные результаты показали, что характеристики цветовых стимулов могут быть восстановлены из представлений модели.

В настоящей работе рассматривается другая постановка: физический центральный цвет сохраняется неизменным, а изменяются условия его наблюдения. Поэтому анализируется не абсолютное представление цвета, а изменение представления одного и того же физического стимула при изменении визуального контекста.

2.2 LUTCHI и модели цветового восприятия

Данные LUTCHI были получены в серии психофизических экспериментов по исследованию внешнего вида цвета [7,8,9]. Наблюдатели оценивали цветовые стимулы при различных условиях наблюдения; среди представленных характеристик — светлота, полнота цвета и цветовой тон. Наличие повторных измерений для одних и тех же физических цветов позволяет оценивать изменение человеческого восприятия при изменении визуального контекста.

Для дополнительного сравнения используется CAM16 [4] — модель цветового восприятия, учитывающая условия наблюдения. В работе изменения характеристик CAM16 сопоставляются с человеческими изменениями для тех же физических цветов.

3 Постановка задачи

Для каждого физического цвета i в данных LUTCHI известны человеческие оценки

$$y_{i,s} = (L_{i,s}, C_{i,s}, h_{i,s})$$

в условии наблюдения s, где L — светлота, C — полнота цвета, h — цветовой тон. Для соответствующего изображения из Qwen2.5-VL извлекается внутреннее представление

$$e_{i,s} \in \mathbb{R}^{3584}.$$

В обозначении условий первая буква задаёт фон, а вторая — окружение; b, g и w соответствуют чёрному, серому и белому вариантам. В качестве опорного используется условие gg. Для одного и того же физического центрального цвета рассматриваются переходы $gg \to bb$, $gg \to gb$, $gg \to gw$ и $gg \to ww$.

Для каждого перехода определяются изменение человеческой оценки

$$\Delta y_{i,s} = y_{i,s} - y_{i,gg}$$

и соответствующее изменение внутреннего представления

$$\Delta e_{i,s} = e_{i,s} - e_{i,gg}.$$

Для цветового тона используется кратчайшая циклическая разность с периодом 400, соответствующим шкале LUTCHI.

Основной вопрос состоит в том, можно ли по изменению внутреннего представления модели предсказать соответствующее изменение человеческой оценки для физического цвета, который не использовался при обучении регрессии.

Отдельно анализируются представления визуального энкодера, скрытые состояния языковой части перед генерацией и явные численные ответы модели.

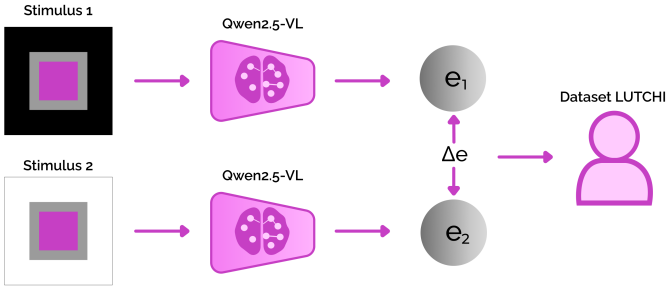


Рис. 1. Общая схема эксперимента. Один и тот же физический центральный цвет предъявляется при различных условиях наблюдения. Изменение внутреннего представления модели сопоставляется с изменением человеческой оценки цветового восприятия по данным LUTCHI.

4 Данные и методика

4.1 Данные LUTCHI и формирование выборки

В работе используются данные LUTCHI [7,8,9], полученные в психофизических экспериментах по оценке внешнего вида цвета при различных условиях наблюдения. Для каждого стимула доступны колориметрические координаты центрального цвета (x, y, Y), усреднённые по наблюдателям оценки светлоты L, полноты цвета C и цветового тона h, а также параметры условий наблюдения.

В анализ включены пять условий группы CRT: bb, gb, gg, gw и ww, различающихся сочетанием фона и окружения. Их параметры приведены в табл. 1. Для условий bb, gb, gg и gw доступно по 100 стимулов, для ww — 94; всего выборка содержит 494 изображения.

Для сопоставления одного физического цвета между условиями использовались его колориметрические координаты (x, y, Y), поскольку исходный

Таблица 1. Условия наблюдения группы CRT данных LUTCHI.

Условие	*bb*	*gb*	*gg*	*gw*	*ww*
Число стимулов	100	100	100	100	94
Яркостный коэффициент фона	5	20	20	20	100
Окружение	чёрное	чёрное	серое	белое	белое
Яркость эталона, кд/м^2	44.5	44.5	44.5	44.5	40

идентификатор цвета LUTCHI не во всех случаях однозначно задаёт физический стимул. В результате выделено 100 физических цветов, для 94 из которых представлены все пять рассматриваемых условий.

Условие *gg* используется как опорное. Переходы $gg \to bb$, $gg \to gb$ и $gg \to gw$ содержат по 100 пар физических цветов, а переход $gg \to ww$ — 94 пары. В некоторых переходах одновременно изменяются несколько параметров условий наблюдения, поэтому вклад отдельных факторов не разделяется и каждый переход анализируется отдельно.

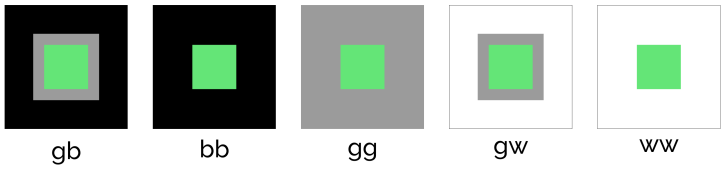


Рис. 2. Примеры условий наблюдения LUTCHI. Центральный физический цвет остаётся неизменным, тогда как фон и окружение изменяются.

4.2 Модель и внутренние представления

В экспериментах используется Qwen2.5-VL-7B-Instruct [1]. В модель подаётся полное изображение LUTCHI размером 224×224 пикселей, содержащее центральный цветовой стимул и его окружение. Изображение не обрезается, поскольку предметом исследования является изменение представления при изменении визуального контекста.

Анализируются два типа внутренних представлений модели, а также её явный численный ответ.

Визуальный энкодер. После обработки изображения получается сетка 8×8 из 64 векторов размерности 3584. В качестве представления центрального стимула используется среднее четырёх центральных векторов.

Языковая часть. В модель подаётся то же изображение и фиксированный запрос на оценку воспринимаемого цвета центрального стимула. Используется скрытое состояние последнего слоя для последнего токена запро-

са непосредственно перед генерацией ответа. Его размерность также равна 3584.

Явный ответ. Отдельно модель генерирует численные оценки L, C и h. Для каждой пары условий изменение сгенерированной оценки непосредственно сопоставляется с соответствующим изменением человеческой оценки.

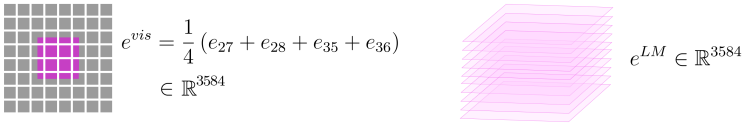


Рис. 3. Исследуемые внутренние представления Qwen2.5-VL: представление центральной области изображения из визуального энкодера и скрытое состояние языковой части перед генерацией ответа.

4.3 Предсказание изменений

Для восстановления человеческих изменений из внутренних представлений используется гребневая линейная регрессия (Ridge) [3]. Входом регрессии является изменение представления, а целевыми переменными — соответствующие изменения ΔL, ΔC и Δh. Регрессия отдельно обучается для представлений визуального энкодера и скрытых состояний языковой части.

Для явных ответов дополнительная регрессия не используется: изменение сгенерированной моделью оценки непосредственно сравнивается с изменением человеческой оценки.

В качестве базового уровня используется предсказание отсутствия изменения, $\widehat{\Delta y} = 0$. Его MAE соответствует средней абсолютной величине человеческого сдвига и показывает ошибку предположения о том, что воспринимаемый цвет при смене условий не изменяется.

Дополнительно для перехода $gg \to ww$ проводится сравнение с CAM16 [4]. Для одних и тех же 94 физических цветов вычисляются изменения характеристик CAM16 между условиями gg и ww и сопоставляются с человеческими изменениями LUTCHI.

4.4 Кросс-валидация и метрики

Качество регрессионных моделей оценивается с помощью групповой кросс-валидации по идентификатору физического цвета. Все наблюдения, относящиеся к одному физическому цвету, попадают только в обучающую либо

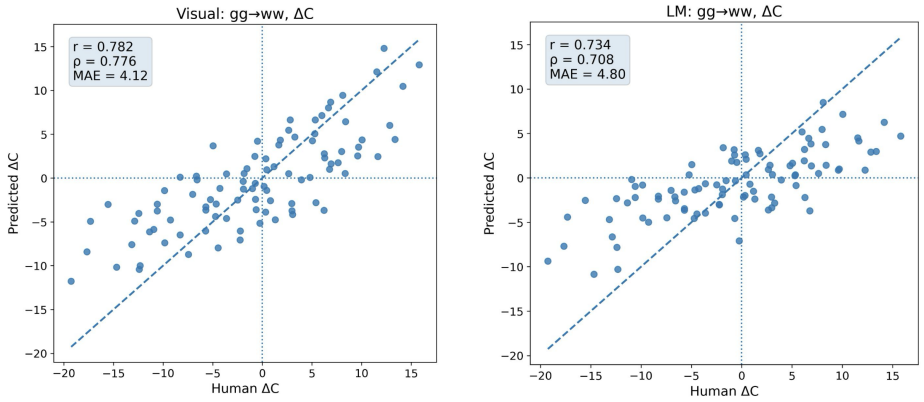
только в тестовую часть. Таким образом, качество оценивается на физических цветах, отсутствовавших при обучении.

Для выбора коэффициента регуляризации Ridge используется вложенная кросс-валидация: пять внешних разбиений для оценки качества и четыре внутренних разбиения для выбора α из множества $\{0.1, 1, 10, 10^2, 10^3, 10^4\}$.

Основной метрикой связи между прогнозируемыми и человеческими изменениями является коэффициент корреляции Пирсона r. Дополнительно используются ранговая корреляция Спирмена ρ и средняя абсолютная ошибка (MAE). Для корреляций и изменений MAE рассчитываются 95 %-ные доверительные интервалы кластерным бутстрапом по физическим цветам с 5000 повторений.

5 Результаты

Изменения внутренних представлений при смене условий наблюдения позволяют в разной степени предсказывать соответствующие изменения человеческих оценок. Наиболее выраженная связь наблюдается для полноты цвета C при переходе $gg \to ww$. Этот результат показан на рис. 4. Сводные значения корреляций для всех рассматриваемых переходов и характеристик приведены в табл. 2.



(а) Визуальный энкодер (б) Языковая часть

Рис. 4. Связь между изменениями человеческих оценок полноты цвета ΔC и вневыборочными прогнозами для перехода $gg \to ww$: (а) представления визуального энкодера; (б) скрытые состояния языковой части. Корреляция Пирсона составляет $r = 0.782$ и $r = 0.734$ соответственно.

Таблица 2. Корреляция Пирсона r между прогнозируемыми и человеческими изменениями характеристик цвета. Звёздочкой отмечены значения, для которых 95 %-ный бутстрап-доверительный интервал не содержит ноль.

Переход	Признак	Визуальный энкодер	Скрытое состояние LM	Явный ответ
$gg \to bb$	L	0.407*	0.289*	0.088
	C	0.293*	0.071	0.155
	h	0.124	0.026	0.053
$gg \to gb$	L	0.342*	0.169	−0.180
	C	0.259*	0.144	−0.104
	h	0.258*	0.046	−0.076
$gg \to gw$	L	0.292*	0.259*	−0.027
	C	0.319*	0.164	0.207*
	h	0.116	−0.097	0.008
$gg \to ww$	L	0.416*	0.339*	−0.034
	C	**0.782***	**0.734***	0.415*
	h	0.003	−0.172	−0.181

5.1 Внутренние представления

Для светлоты L представления визуального энкодера дают положительную корреляцию с человеческими изменениями во всех четырёх переходах: $r = 0.407$ для $gg \to bb$, 0.342 для $gg \to gb$, 0.292 для $gg \to gw$ и 0.416 для $gg \to ww$. Во всех четырёх случаях 95 %-ный доверительный интервал корреляции не содержит ноль. Для скрытых состояний языковой части связь слабее; ненулевые корреляции получены для $gg \to bb$, $gg \to gw$ и $gg \to ww$.

Для перехода $gg \to ww$ визуальные представления существенно уменьшают абсолютную ошибку предсказания светлоты: MAE составляет 3.14 против 10.39 для предсказания отсутствия изменения. Для скрытых состояний языковой части MAE равна 3.16.

Наиболее выраженный результат наблюдается для полноты цвета C при переходе $gg \to ww$. Корреляция для представлений визуального энкодера составляет $r = 0.782$ с 95 %-ным доверительным интервалом $[0.708; 0.844]$, а для скрытых состояний языковой части — $r = 0.734$ с интервалом $[0.639; 0.808]$. MAE визуального представления составляет 4.12 против 6.47 для нулевого базового предсказания; 95 %-ный доверительный интервал уменьшения ошибки равен $[1.56; 3.18]$.

Для цветового тона h связь существенно слабее. Для визуальных представлений доверительный интервал корреляции не содержит ноль только в переходе $gg \to gb$, где $r = 0.258$. Для перехода $gg \to ww$ линейная корреляция практически отсутствует: $r = 0.003$ для визуального представления и $r = -0.172$ для скрытого состояния языковой части.

Таблица 3. Сравнение представлений визуального энкодера Qwen и CAM16 для перехода $gg \to ww$ на 94 одинаковых физических цветах.

Признак	Метод	Pearson r	Spearman ρ	MAE
L	Qwen Visual	0.416	0.409	**3.14**
	CAM16	0.089	−0.076	3.89
C	Qwen Visual	**0.782**	**0.776**	**4.12**
	CAM16	0.641	0.551	5.93
h	Qwen Visual	0.003	0.382	**18.07**
	CAM16	−0.059	−0.407	19.39

5.2 Явные численные ответы

Явные численные ответы модели в целом слабее отражают различия между человеческими изменениями, чем внутренние представления.

Для полноты цвета в переходе $gg \to ww$ наблюдается положительная корреляция $r = 0.415$ с 95 %-ным доверительным интервалом $[0.253; 0.557]$. При этом MAE явного ответа составляет 6.87, тогда как ошибка предсказания отсутствия изменения равна 6.47. Таким образом, явный ответ отражает часть относительных различий между цветами, но не уменьшает абсолютную ошибку относительно нулевого базового предсказания.

Для полноты цвета в переходе $gg \to gw$ также получена положительная корреляция ($r = 0.207$), однако MAE явного ответа равна 7.18 против 3.46 у нулевого предсказания. Для большинства остальных сочетаний перехода и характеристики доверительный интервал корреляции явного ответа содержит ноль.

Для явных ответов также характерна большая доля случаев, в которых модель не изменяет численную оценку между двумя условиями. В переходе $gg \to ww$ нулевой сдвиг получен в 90.4 % случаев для L, 71.3 % для C и 55.3 % для h.

Единственный случай, в котором явный ответ достоверно уменьшает MAE относительно нулевого предсказания, получен для светлоты в переходе $gg \to ww$: ошибка уменьшается с 10.39 до 10.03. При этом корреляция с индивидуальными человеческими сдвигами практически отсутствует ($r = -0.034$).

5.3 Сравнение с CAM16

Для перехода $gg \to ww$ проведено прямое сравнение с CAM16 на одинаковом наборе из 94 физических цветов. Результаты приведены в табл. 3.

Для полноты цвета визуальные представления Qwen показывают более высокую связь с человеческими изменениями на рассматриваемой выборке: $r = 0.782$ и $\rho = 0.776$ против $r = 0.641$ и $\rho = 0.551$ у CAM16. MAE составляет соответственно 4.12 и 5.93. Для светлоты MAE равна 3.14 для Qwen и 3.89 для CAM16, а корреляция Пирсона — 0.416 и 0.089 соответственно.

Для цветового тона линейная корреляция мала у обоих методов. Полученные результаты поэтому не показывают устойчивого воспроизведения человеческих изменений h ни одним из рассматриваемых подходов.

6 Обсуждение

Полученные результаты показывают, что контекстно-зависимая информация о цвете в Qwen2.5-VL в большей степени доступна во внутренних представлениях, чем в конечных численных ответах. Наиболее информативными оказались признаки визуального энкодера; скрытые состояния языковой части также содержат эту информацию, но в среднем выражают её слабее. Наиболее отчётливо это проявилось для полноты цвета при переходе $gg \to ww$.

Сравнение с CAM16 относится только к рассматриваемой выборке и одному переходу. Оно показывает, что для полноты цвета внутренние представления Qwen на этих данных сильнее согласуются с человеческими изменениями, но не является общей оценкой качества CAM16 или мультимодальных моделей.

Исследование ограничено одной мультимодальной моделью и небольшим числом физических цветовых стимулов. Кроме того, в части переходов одновременно изменяются несколько параметров условий наблюдения, поэтому их вклад не разделяется. Наконец, возможность декодировать человеческие оценки из внутренних представлений не означает сходства механизмов обработки цвета в модели и человеческой зрительной системе.

7 Выводы

Предложен подход к анализу контекстно-зависимых изменений цветовых представлений мультимодальной модели на психофизических данных LUTCHI.

Показано, что изменения внутренних представлений Qwen2.5-VL позволяют предсказывать часть изменений человеческих оценок одного и того же физического цвета при смене условий наблюдения. Наиболее устойчивый результат получен для полноты цвета при переходе $gg \to ww$ ($r = 0.782$); конечные численные ответы модели отражают эту информацию существенно слабее.

Дальнейшая работа может включать проверку на других мультимодальных моделях, расширение набора стимулов и отдельный анализ влияния фона, окружения и адаптации.

Работа выполнена в рамках государственного задания №FFNU-2025-0045 ИППИ РАН, утвержденного Минобрнауки России.

Список литературы

1. Bai, S., Chen, K., Liu, X., Wang, J., Ge, W., Song, S., Dang, K., Wang, P., Wang, S., Tang, J., Zhong, H., Zhu, Y., Yang, M., Li, Z., Wan, J., Wang, P., Ding, W., Fu, Z., Xu, Y., Ye, J., Zhang, X., Xie, T., Cheng, Z., Zhang, H., Yang, Z., Xu, H., Lin, J.: Qwen2.5-VL technical report. arXiv preprint arXiv:2502.13923 (2025)
2. Fairchild, M.D.: Color Appearance Models. John Wiley & Sons, 3 edn. (2013). https://doi.org/10.1002/9781118653128
3. Hoerl, A.E., Kennard, R.W.: Ridge regression: Biased estimation for nonorthogonal problems. Technometrics **12**(1), 55–67 (1970). https://doi.org/10.1080/00401706.1970.10488634
4. Li, C., Li, Z., Wang, Z., Xu, Y., Luo, M.R., Cui, G., Melgosa, M., Brill, M.H., Pointer, M.: Comprehensive color solutions: CAM16, CAT16, and CAM16-UCS. Color Research & Application **42**(6), 703–718 (2017). https://doi.org/10.1002/col.22131
5. Liang, Y., Li, M., Fan, C., Li, Z., Nguyen, D., Cobbina, K., Bhardwaj, S., Chen, J., Liu, F., Zhou, T.: ColorBench: Can VLMs see and understand the colorful world? a comprehensive benchmark for color perception, reasoning, and robustness. In: Advances in Neural Information Processing Systems. vol. 38. Curran Associates, Inc. (2025). https://doi.org/10.52202/085713-4803
6. Lobarev, G., Kolomiets, A., Karpenko, S., Ershov, E.: Linear decoding of perceptual color spaces from multimodal large language models. In: London Imaging Meeting (2026), in print
7. Luo, M.R., Clarke, A.A., Rhodes, P.A., Schappo, A., Scrivener, S.A.R., Tait, C.J.: Quantifying colour appearance. part i. LUTCHI colour appearance data. Color Research & Application **16**(3), 166–180 (1991). https://doi.org/10.1002/col.5080160307
8. Luo, M.R., Clarke, A.A., Rhodes, P.A., Schappo, A., Scrivener, S.A.R., Tait, C.J.: Quantifying colour appearance. part ii. testing colour models performance using LUTCHI colour appearance data. Color Research & Application **16**(3), 181–197 (1991). https://doi.org/10.1002/col.5080160308
9. Luo, M.R., Gao, X.W., Rhodes, P.A., Xin, H.J., Clarke, A.A., Scrivener, S.A.R.: Quantifying colour appearance. part iii. supplementary LUTCHI colour appearance data. Color Research & Application **18**(2), 98–113 (1993). https://doi.org/10.1002/col.5080180207