Анализ различий между токенными эмбеддингами MLLM

1 Цель эксперимента

Целью эксперимента является анализ структуры токенных embedding-представлений мультимодальных моделей и проверка различий между отдельными токенами внутри одного изображения.

Основной вопрос исследования:

> Возникает ли наблюдаемое распределение расстояний между токенами вследствие содержательной информации изображения или оно может быть связано с позиционным кодированием RoPE?

2 Исходные данные

Для анализа использовались embedding-представления моделей:

- InternVL3-2B;
- InternVL3-8B;
- InternVL3-14B;
- Phi-4.

Рассматривались два типа представлений:

- vision embeddings;
- projected embeddings.

Для моделей InternVL сохранённые эмбеддинги имели структуру:

$$(batch, tokens, embedding_dim)$$

Например:

$$(1, 1024, 1024)$$

После удаления batch-размерности:

$$(tokens, embedding_dim)$$

каждая строка соответствовала отдельному токенному embedding-вектору.

Для Phi-4 в сохранённых данных присутствовал только один pooled embedding:

$$(1, 1, d)$$

Таким образом, последовательность токенов отсутствовала, поэтому межтокенный анализ для Phi-4 невозможен.

3 Используемые метрики

3.1 Cosine similarity

Для оценки сходства направлений embedding-векторов использовалась косинусная близость:

$$cos(x, y) = \frac{x^T y}{||x||\,||y||}$$

Чем ближе значение к 1, тем более похожи направления двух векторов.

3.2 NRMSE

Для оценки различий между значениями компонент использовалась нормированная RMSE:

$$NRMSE(x, y) = \frac{\sqrt{\frac{1}{d}\sum_i (x_i - y_i)^2}}{\sqrt{\frac{1}{d}\sum_i x_i^2}}$$

Метрика показывает относительное отличие двух embedding-векторов.

4 Эксперимент 1: сравнение всех токенов между собой

В первом эксперименте рассматривались все пары токенов:

$$(t_i, t_j), \quad i \neq j$$

Для каждой пары вычислялись:

$$cos(t_i, t_j)$$

и

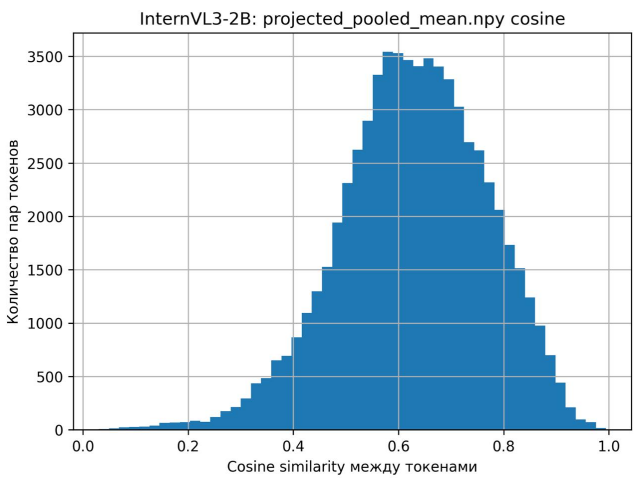
$$NRMSE(t_i, t_j)$$

Таким образом исследовалось полное распределение расстояний между токенными представлениями.

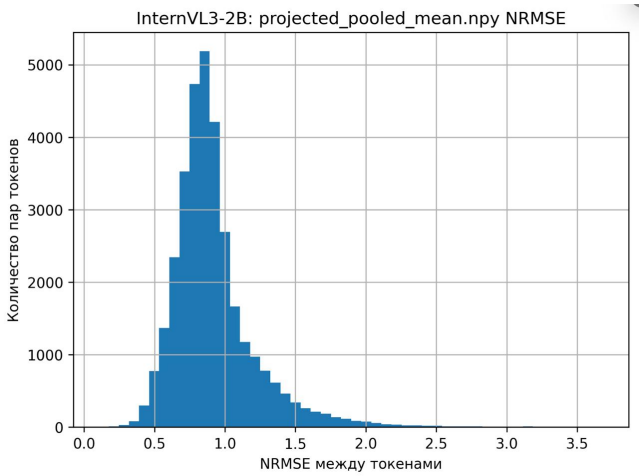
4.1 Средние значения

Модель	Представление	Cosine mean	NRMSE mean
InternVL3-2B	vision	0.725	0.796
InternVL3-2B	projected	0.480	1.271
InternVL3-8B	vision	0.413	0.967
InternVL3-8B	projected	0.387	1.278
InternVL3-14B	vision	0.305	1.050
InternVL3-14B	projected	0.362	1.150

4.2 Гистограммы all-to-all

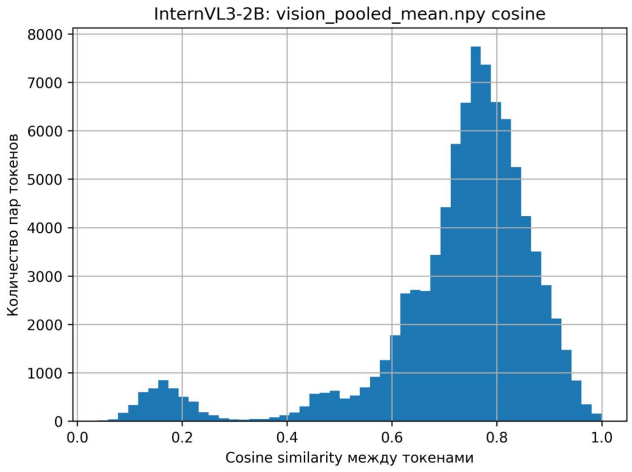


(a) Cosine similarity

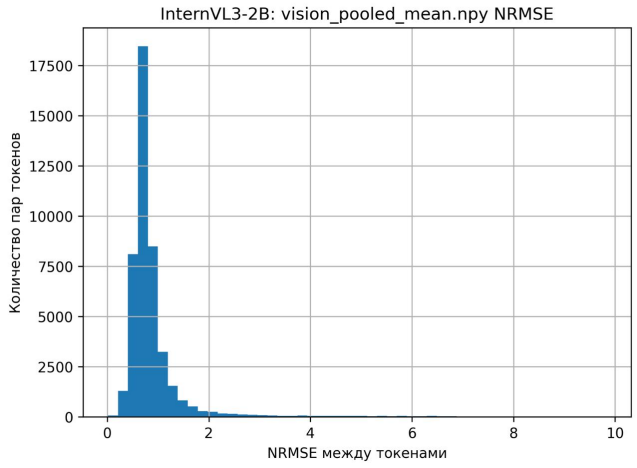


(b) NRMSE

Рис. 1: InternVL3-2B vision. Все токены сравниваются между собой.

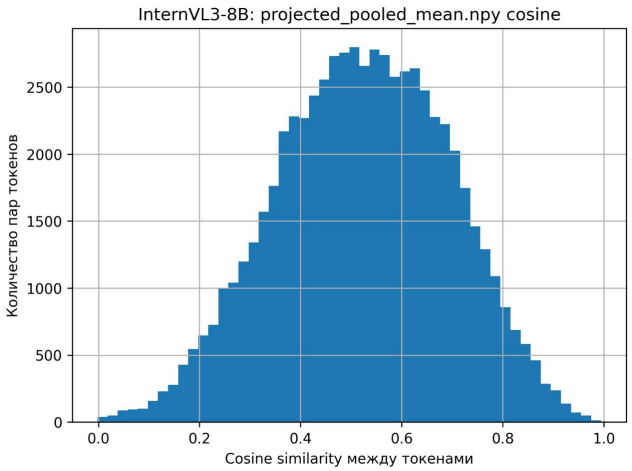


(a) Cosine similarity

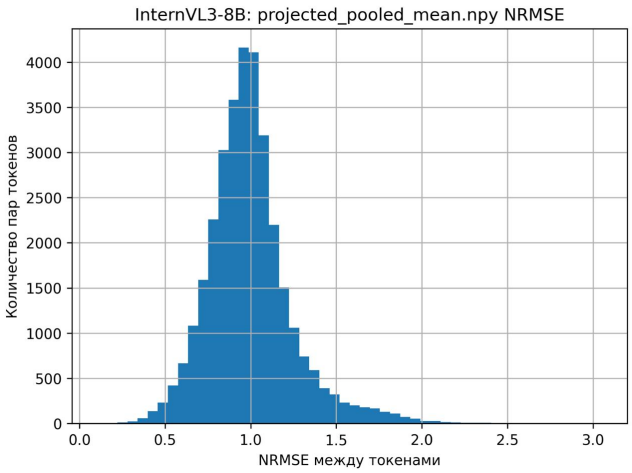


(b) NRMSE

Рис. 2: InternVL3-2B projected. Все токены сравниваются между собой.

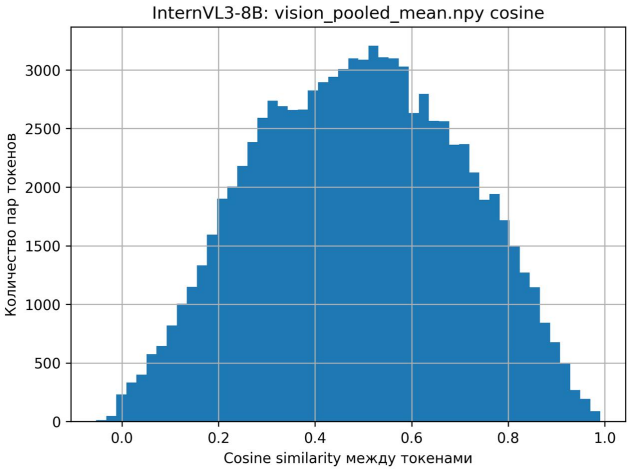


(a) Cosine similarity

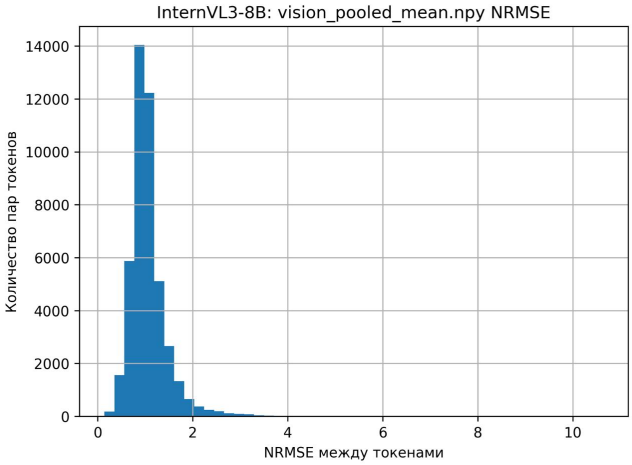


(b) NRMSE

Рис. 3: InternVL3-8B vision. Все токены сравниваются между собой.

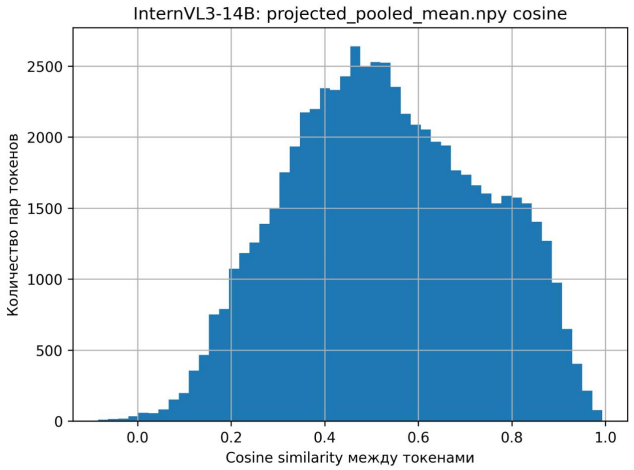


(a) Cosine similarity

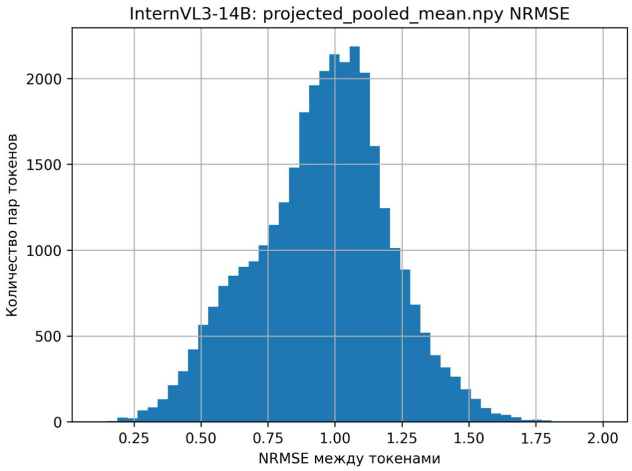


(b) NRMSE

Рис. 4: InternVL3-8B projected. Все токены сравниваются между собой.

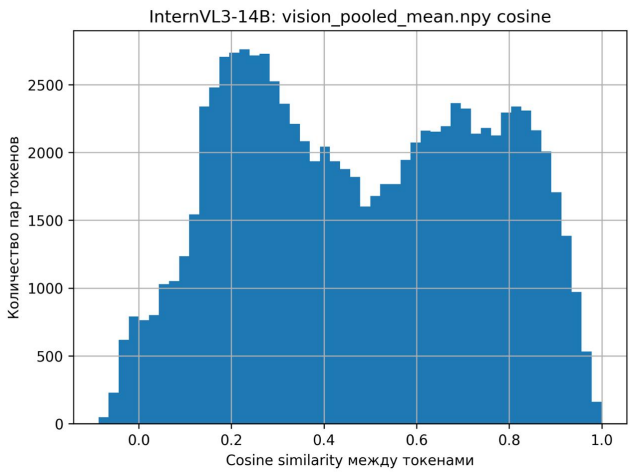


(a) Cosine similarity

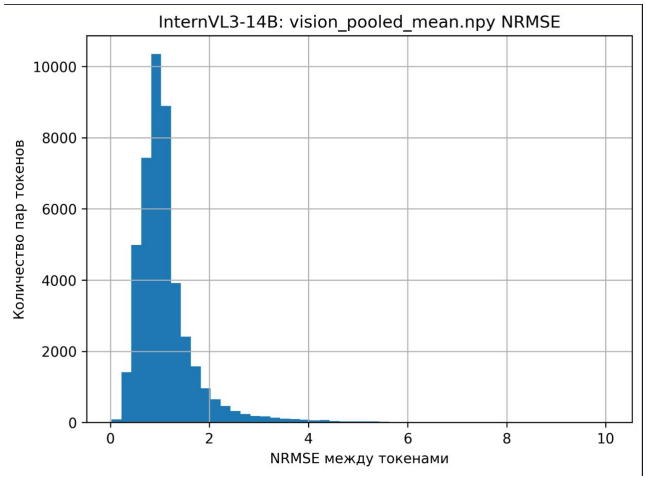


(b) NRMSE

Рис. 5: InternVL3-14B vision. Все токены сравниваются между собой.



(a) Cosine similarity



(b) NRMSE

Рис. 6: InternVL3-14B projected. Все токены сравниваются между собой.

5 Эксперимент 2: первый токен против всех

Во втором эксперименте фиксировался первый токен:

$$t_0$$

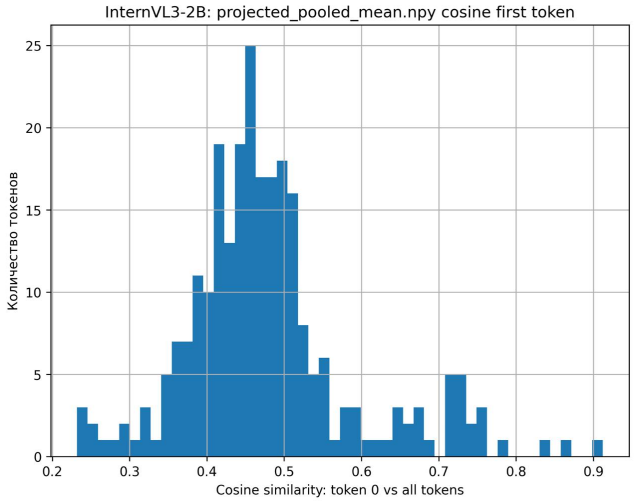
и вычислялись:

$$cos(t_0, t_i)$$

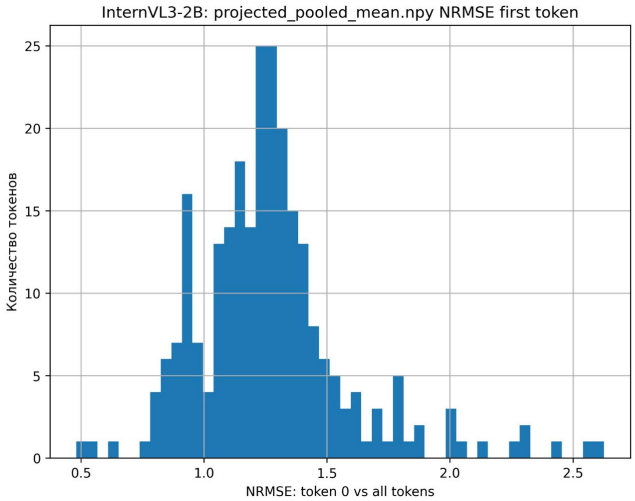
$$NRMSE(t_0, t_i)$$

Данный эксперимент позволяет проверить, является ли первый токен особенным относительно остальных токенов.

5.1 Гистограммы распределений

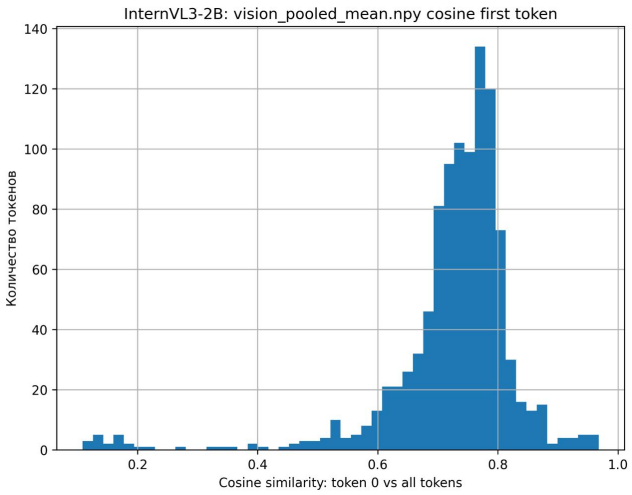


(a) Cosine similarity

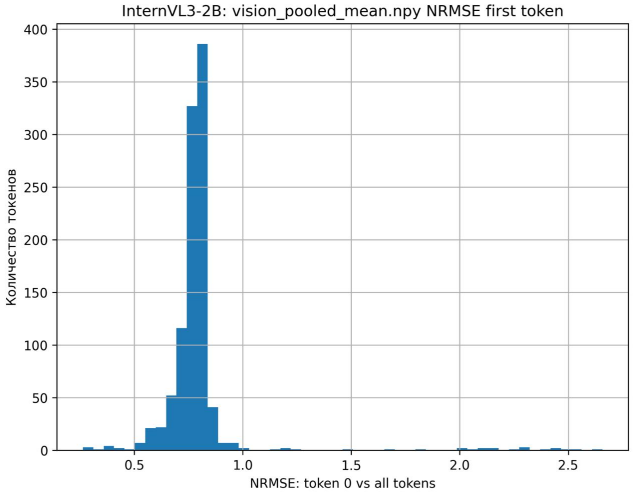


(b) NRMSE

Рис. 7: InternVL3-2B vision. Первый токен сравнивается со всеми остальными токенами.

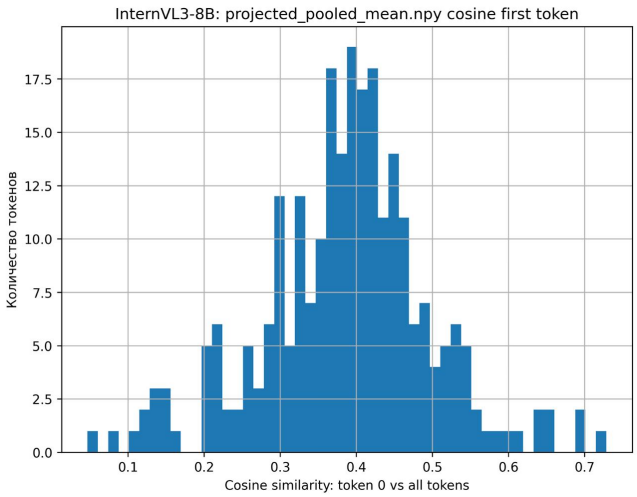


(a) Cosine similarity

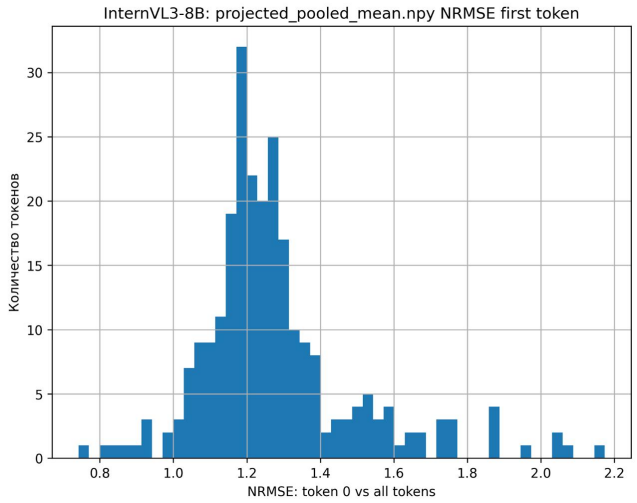


(b) NRMSE

Рис. 8: InternVL3-2B projected. Первый токен сравнивается со всеми остальными токенами.

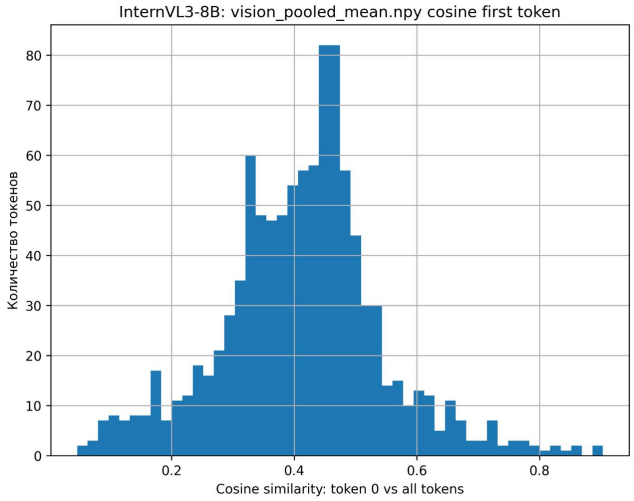


(a) Cosine similarity

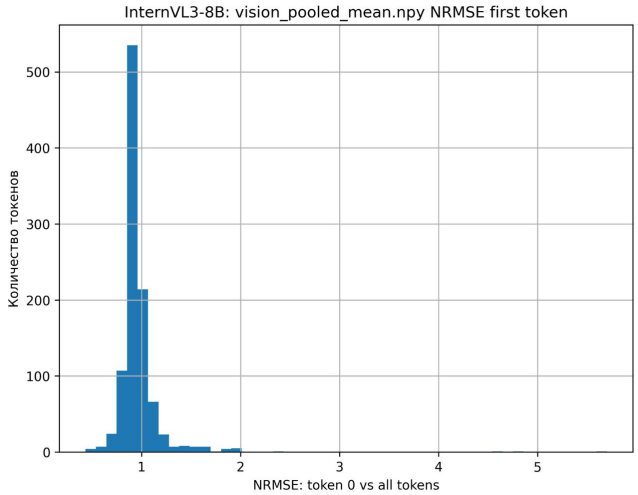


(b) NRMSE

Рис. 9: InternVL3-8B vision. Первый токен сравнивается со всеми остальными токенами.

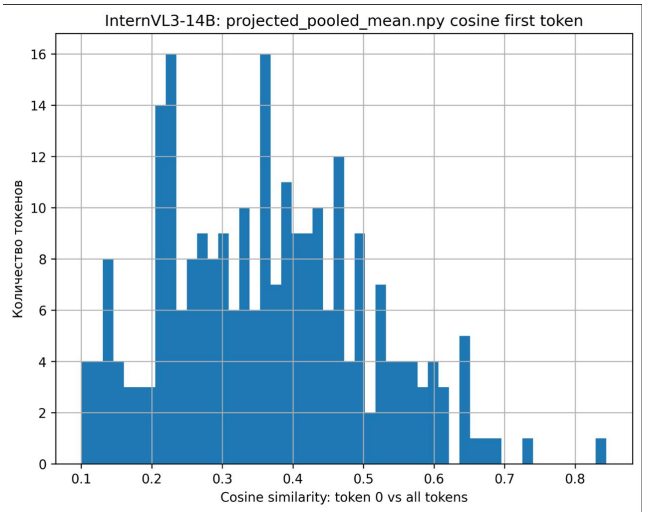


(a) Cosine similarity

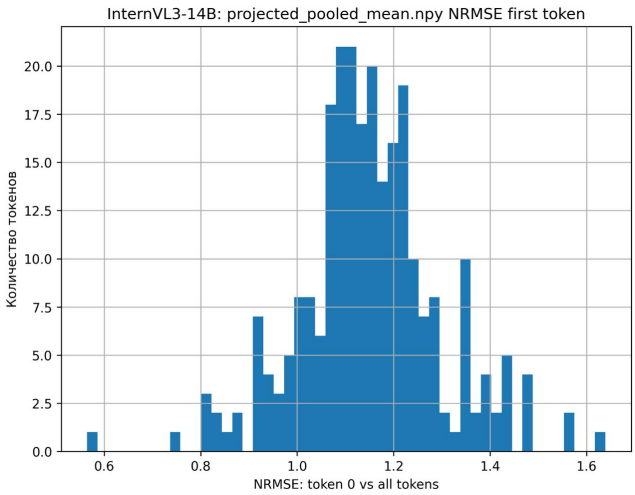


(b) NRMSE

Рис. 10: InternVL3-8B projected. Первый токен сравнивается со всеми остальными токенами.

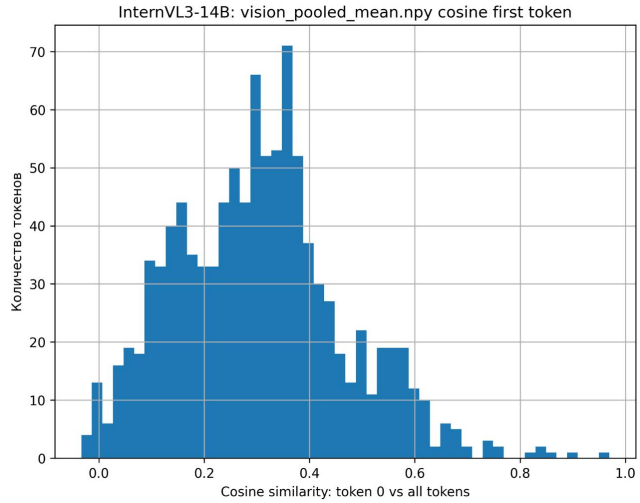


(a) Cosine similarity

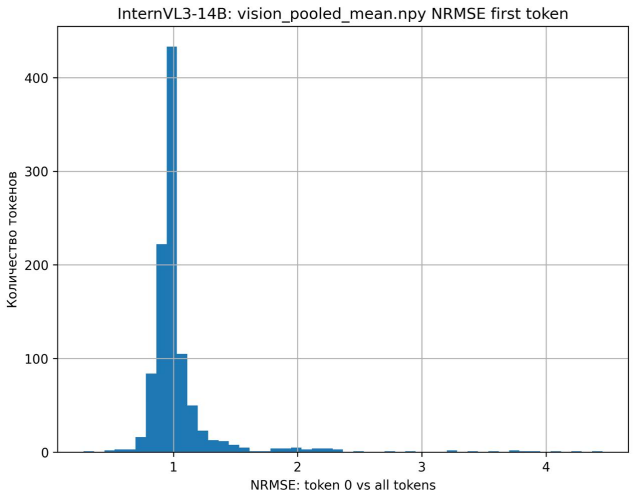


(b) NRMSE

Рис. 11: InternVL3-14B vision. Первый токен сравнивается со всеми остальными токенами.



(a) Cosine similarity



(b) NRMSE

Рис. 12: InternVL3-14B projected. Первый токен сравнивается со всеми остальными токенами.

6 Эксперимент 3: влияние RoPE

Для проверки влияния позиционного кодирования был проведён контрольный эксперимент. Был создан случайный embedding-вектор:

$$x \in R^{1024}$$

Затем были созданы одинаковые копии:

$$x_1 = x_2 = ... = x_N$$

К каждому вектору применялось позиционное вращение RoPE:

$$x'_i = RoPE(x, i)$$

После чего вычислялись расстояния:

$$cos(x'_0, x'_i)$$

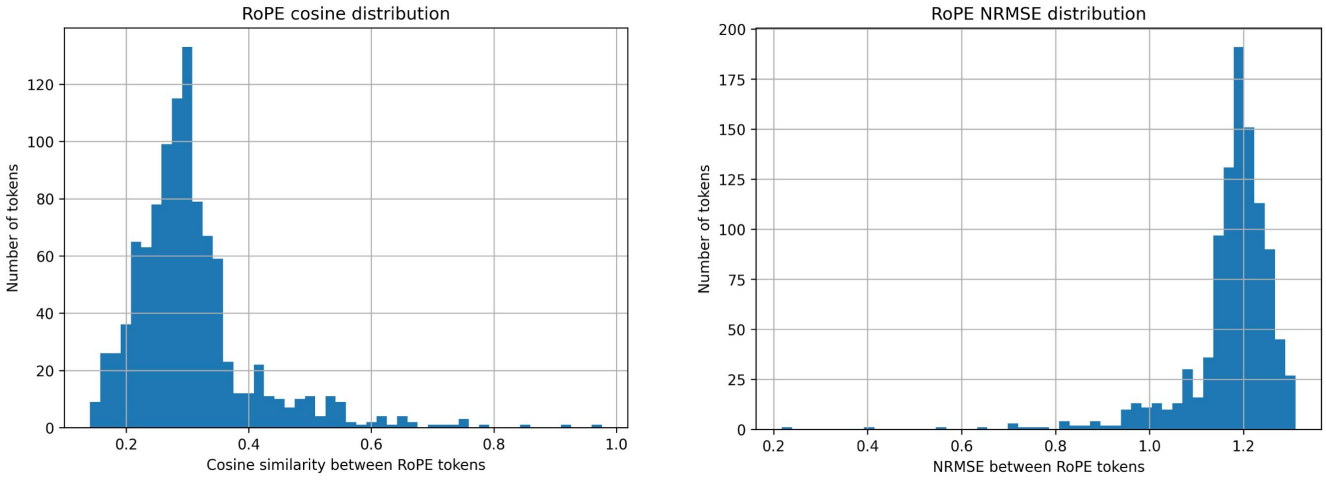
и

$$NRMSE(x'_0, x'_i)$$

Были протестированы две реализации RoPE.

6.1 Результаты RoPE

Эксперимент	Cosine mean	NRMSE mean
RoPE (упрощенный)	0.306	1.174
RoPE (pairwise rotation)	0.282	1.193



(a) Cosine similarity

(b) NRMSE

Рис. 13: Распределение расстояний после применения RoPE к одинаковым векторам.

7 Выводы

Проведён анализ различий между токенными embedding-представлениями мультимодальных моделей.

Было показано, что различные токены одного изображения имеют различающиеся embedding-представления.

Также проведён контрольный эксперимент с RoPE: даже при одинаковых исходных векторах применение позиционного кодирования создаёт распределение расстояний между токенами.

Для точной реализации RoPE получены значения:

$$cosine \approx 0.28$$

$$NRMSE \approx 1.19$$

Эти значения находятся в диапазоне, близком к некоторым реальным embedding-представлениям InternVL, что показывает возможное влияние позиционного кодирования на наблюдаемое распределение.

Следующим этапом является сравнение формы распределений RoPE и реальных эмбеддингов для оценки вклада позиционного кодирования и содержательной информации изображения.