Исследование структуры визуальных токенов мультимодальной модели Qwen

Эксперимент: восстановление цветовой информации из visual embeddings

1 Проверка гипотезы: соответствует ли количество кластеров количеству цветов

В работе исследуется структура визуальных токенов мультимодальной модели Qwen и проверяется, насколько цветовая информация сохраняется во внутренних visual embeddings.

Были поставлены следующие задачи:

- выполнить KMeans-кластеризацию visual tokens одного изображения;
- сравнить кластеризацию одного центрального цветового патча при различных фонах;
- построить графики значений компонент эмбеддингов одного изображения;
- обучить линейное отображение из совокупности токенов одного изображения в координаты LCH;
- разделить изображения на обучающую и тестовую выборки;
- сравнить качество модели на train- и test-выборках;
- определить наиболее информативные пространственные области;
- обучить отдельные регрессии по глобальным KMeans-кластерам;
- построить пространственные карты весов линейного отображения;
- проверить, существуют ли зануляющиеся visual embeddings, соответствующие центральному цветовому патчу.

1.1 Описание данных

В работе использовались визуальные токены мультимодальной модели Qwen.

После обработки изображения модель формирует 64 визуальных токена, которые можно представить в виде пространственной сетки

$$8 \times 8.$$

Каждый токен является embedding-вектором размерности 3584:

$$\boldsymbol{z}_i \in \mathbb{R}^{3584}, \qquad i = 1, \ldots, 64.$$

Матрица токенов одного изображения имеет размер

$$Z \in \mathbb{R}^{64 \times 3584}.$$

В качестве исходных данных использовались изображения, сформированные на основе цветовых стимулов LUTCHI. Для каждого изображения известны координаты цвета

$$(L, C, h),$$

где:

- L — светлота;
- C — красочность;
- h — цветовой тон.

Всего было использовано

$$494$$

изображения.

Полный массив visual embeddings имеет размерность

$$494 \times 64 \times 3584.$$

2 Кластеризация visual tokens одного изображения

2.1 Метод

Для проверки наличия структуры в пространстве visual embeddings использовался алгоритм KMeans.

Для токенов одного изображения решалась задача

$$\min_{\boldsymbol{\mu}_1,\ldots,\boldsymbol{\mu}_K} \sum_{i=1}^{64} \min_{k\in\{1,\ldots,K\}} \|\boldsymbol{z}_i - \boldsymbol{\mu}_k\|_2^2,$$

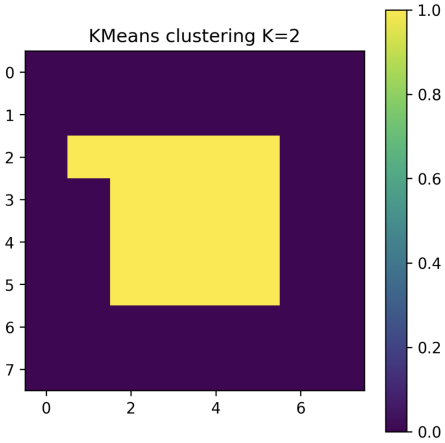
где $\boldsymbol{\mu}_k$ — центр k-го кластера.

Кластеризация выполнялась для

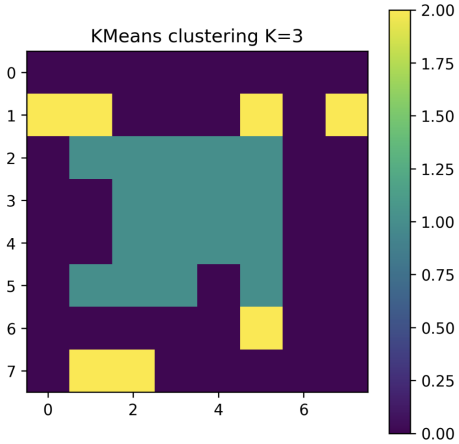
$$K = 2, 3, 4, 5.$$

После получения кластерных меток последовательность из 64 значений преобразовывалась обратно в пространственную карту

$$8 \times 8.$$

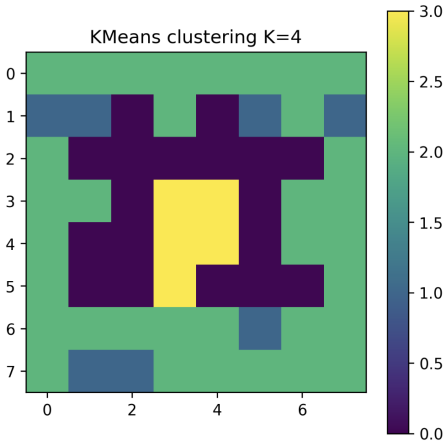


(a) Кластеризация при $K = 2$.

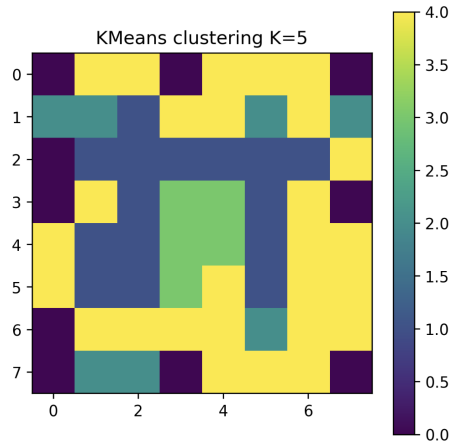


(b) Кластеризация при $K = 3$.

Figure 1: KMeans-кластеризация visual tokens одного изображения.



(a) Кластеризация при $K = 4$.



(b) Кластеризация при $K = 5$.

Figure 2: Результаты кластеризации при большем числе кластеров.

2.2 Результат

Полученные кластеры образуют пространственно связанные области.

Это показывает, что visual embeddings сохраняют информацию о пространственном положении токена и о содержимом соответствующей области изображения.

Однако количество кластеров не совпадает напрямую с количеством физически заданных цветов. Даже однородные по цвету области могут разделяться на несколько кластеров.

На кластеризацию могут влиять:

- цвет соответствующей области;
- положение токена в сетке;
- граница между областями;
- окружающий фон;
- позиционное кодирование модели;

- контекст, полученный токеном после взаимодействия с другими токенами.

Следовательно, гипотеза о строгом соответствии количества кластеров количеству цветов не подтверждается. При этом кластеризация действительно выделяет пространственно и визуально различные части изображения.

3 Кластеризация одного цветового патча при разных фонах

Для проверки влияния окружения использовались изображения одного центрального цветового патча при различных фонах:

$$\{gg, gb, gw, bb, ww\}.$$

Цвет центрального патча оставался неизменным, а окружающая область изменялась.

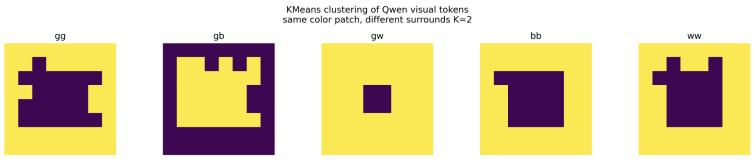


Figure 3: Кластеризация одного центрального цветового патча при различных фонах.

Из рисунка видно, что изменение фона изменяет распределение кластерных меток даже при неизменном центральном цветовом стимуле.

Это означает, что visual embeddings учитывают не только локальный цвет, но и окружающий визуальный контекст.

Такое поведение важно для дальнейшей работы с color appearance, поскольку воспринимаемый вид цвета также зависит от окружения.

4 Анализ значений компонент visual embeddings

4.1 Постановка

Анализ проводился для значений компонент embedding-вектора.

Для токена

$$\boldsymbol{z}_i = (z_{i,1}, z_{i,2}, \ldots, z_{i,3584})$$

строился график зависимости

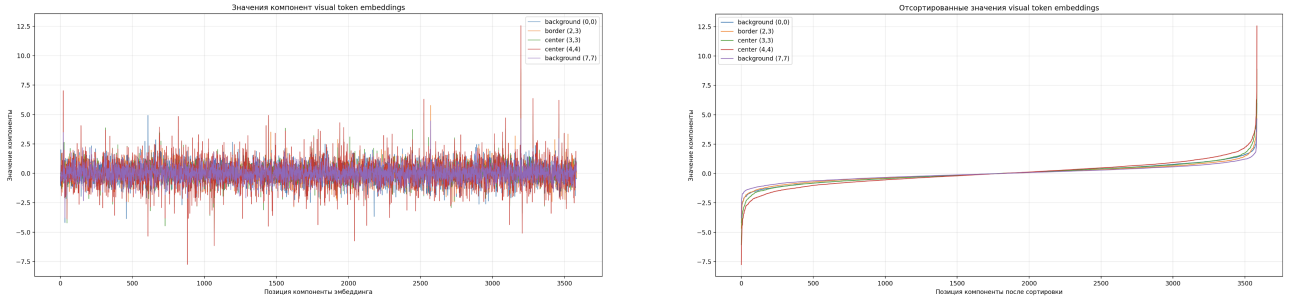
$$j \longmapsto z_{i,j}, \qquad j = 1, \ldots, 3584.$$

По горизонтальной оси откладывался номер компоненты эмбеддинга, а по вертикальной — её значение.

Дополнительно значения каждого эмбеддинга сортировались:

$$z_{i,(1)} \leq z_{i,(2)} \leq \ldots \leq z_{i,(3584)}.$$

Отсортированные значения позволяют сравнить распределения компонент, не учитывая их исходные индексы.



(a) Значения компонент в исходном порядке. **(b)** Отсортированные значения компонент.

Figure 4: Значения visual embeddings одного изображения.

4.2 Результат

На графиках не обнаружено простой структуры, которая позволяла бы однозначно связать определённые компоненты с цветом или положением токена.

Тем не менее видно, что токены различаются:

- по амплитуде отдельных компонент;
- по диапазону значений;
- по форме отсортированного распределения;
- по евклидовой норме.

Следовательно, visual tokens не являются одинаковыми копиями одного embedding-вектора.

5 Первоначальная постановка линейной регрессии

На первом этапе линейное отображение строилось отдельно для каждого visual token:

$$\widehat{\boldsymbol{y}}_i = W\boldsymbol{z}_i + \boldsymbol{b},$$

где

$$\boldsymbol{z}_i \in \mathbb{R}^{3584}, \qquad \widehat{\boldsymbol{y}}_i = (\widehat{L}, \widehat{C}, \widehat{h}).$$

Каждому из 64 токенов одного изображения присваивалась одна и та же целевая метка (L, C, h).

Общее число объектов составляло

$$494 \cdot 64 = 31616.$$

Были получены следующие результаты:

Table 1: Результаты первоначальной токенной регрессии.

Компонента	MAE	R^2
L	4.16	0.898
C	4.50	0.878
h	49.31	0.710

Этот эксперимент показал, что отдельные токены содержат информацию о цвете изображения.

Однако такая постановка не является полностью корректной:

- токены одного изображения не являются независимыми объектами;
- всем токенам присваивается одинаковая целевая метка;
- при случайном разбиении токенов части одного изображения могут попасть одновременно в train и test;
- модель не использует совокупное представление изображения.

Поэтому далее регрессия была переделана в трёх вариантах:

1. по всем токенам одного изображения;
2. по выбранным пространственным областям;
3. по токенам глобальных KMeans-кластеров.

6 Регрессия по всем токенам одного изображения

6.1 Формирование признакового вектора

Для каждого изображения все 64 visual embeddings объединялись в один длинный вектор:

$$\boldsymbol{x} = \mathrm{vec}(Z).$$

Его размерность составляет

$$64 \cdot 3584 = 229376.$$

Теперь одному изображению соответствует один объект:

$$\boldsymbol{x}_n \in \mathbb{R}^{229376}, \qquad \boldsymbol{y}_n = (L_n, C_n, h_n).$$

Изображения разделялись на обучающую и тестовую выборки:

$$395 \text{ train-изображений}, \qquad 99 \text{ test-изображений}.$$

Для всех признаков выполнялась стандартизация, после чего обучалась Ridge-регрессия:

$$\widehat{W} = \arg\min_{W} \left(\|Y - XW\|_F^2 + \alpha \|W\|_F^2 \right).$$

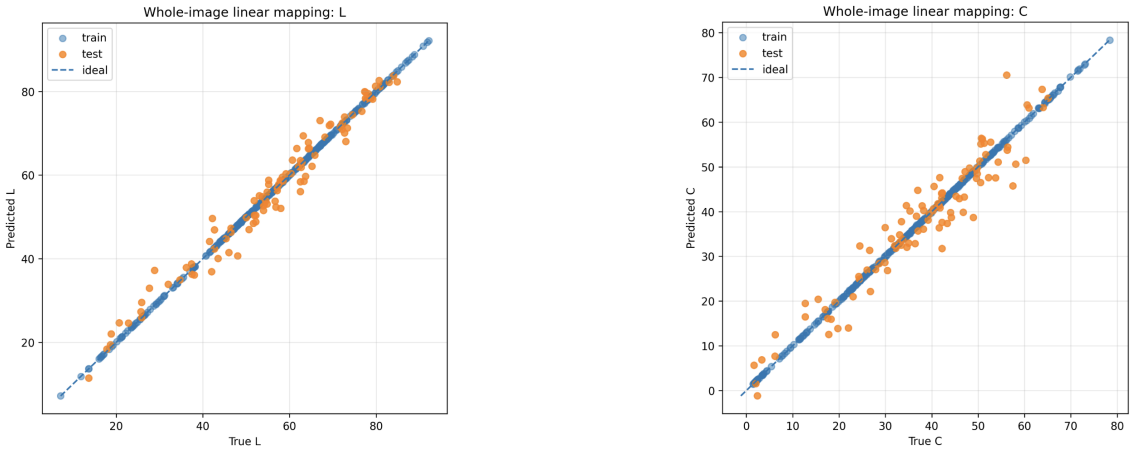
Использовался коэффициент регуляризации

$$\alpha = 100.$$

6.2 Результаты

Table 2: Регрессия по всем 64 токенам изображения.

Компонента	Train MAE	Test MAE	Train R^2	Test R^2
L	0.047	2.20	1.000	0.971
C	0.063	3.35	1.000	0.915
h	1.10	49.99	0.9998	0.748



(a) Истинные и предсказанные значения L.

(b) Истинные и предсказанные значения C.

Figure 5: Результаты регрессии по всем токенам.

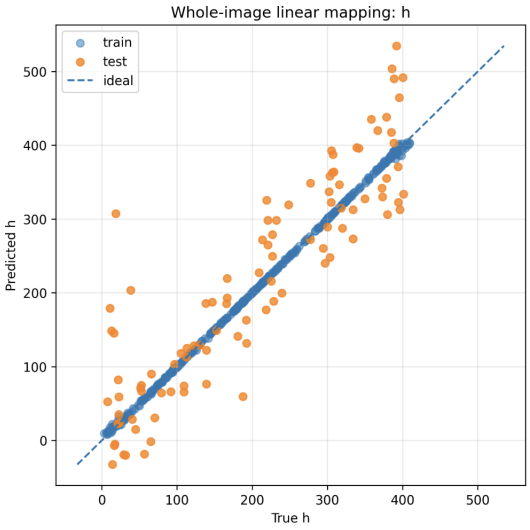


Figure 6: Истинные и предсказанные значения цветового тона h.

6.3 Анализ переобучения

На обучающей выборке модель практически идеально восстанавливает все три компоненты.

Однако качество на тестовой выборке заметно ниже, особенно для h:

$$R^2_{\text{train}}(h) = 0.9998, \qquad R^2_{\text{test}}(h) = 0.748.$$

Это указывает на сильное переобучение.

Основной причиной может быть высокая размерность признаков:

$$229376$$

признаков при

$$395$$

обучающих изображениях.

Несмотря на регуляризацию, модель может запоминать обучающую выборку.

7 Пространственные карты весов линейного отображения

После обучения коэффициенты линейной модели для каждой выходной компоненты возвращались к форме

$$64 \times 3584.$$

Для каждого токена вычислялась норма соответствующего блока весов:

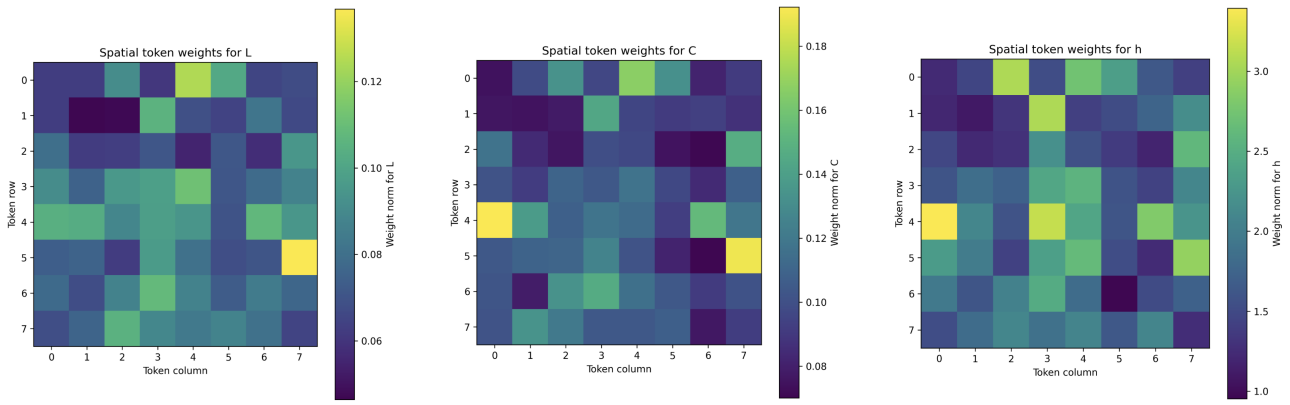
$$I_t^{(q)} = \|W_{q,t,:}\|_2 \,,$$

где

$$q \in \{L, C, h\}, \qquad t = 1, \ldots, 64.$$

Полученные 64 значения преобразовывались в пространственную карту

$$8 \times 8.$$



(a) Карта весов для L. **(b)** Карта весов для C. **(c)** Карта весов для h.

Figure 7: Пространственные карты весов линейного отображения visual tokens в компоненты LCH.

Карта показывает, какие пространственные позиции получили большие коэффициенты линейной модели.

При этом большую норму весов нельзя напрямую интерпретировать как доказательство причинной важности токена, поскольку признаки разных токенов могут быть коррелированы.

Для более надёжной проверки информативности были отдельно обучены модели по центральным и фоновым токенам.

8 Регрессия по различным пространственным областям

8.1 Рассмотренные области

Были рассмотрены четыре набора токенов:

- `all_64` — все 64 токена;
- `center_4` — четыре центральных токена;
- `center_16` — центральная область 4×4;
- `background_48` — 48 токенов вне центральной области 4×4.

Для всех вариантов использовалось одинаковое train/test-разбиение.

8.2 Тестовые результаты

Table 3: Сравнение качества для различных пространственных областей.

Область	L MAE	L R^2	C MAE	C R^2	h MAE	h R^2
Все 64 токена	2.20	0.971	3.35	0.915	49.99	0.748
Центральные 4	2.16	0.974	**2.61**	**0.947**	**25.21**	**0.902**
Центральные 16	**2.07**	**0.977**	3.11	0.931	35.77	0.832
Фоновые 48	2.36	0.969	3.37	0.911	53.24	0.721

8.3 Интерпретация

Для светлоты лучший результат получен при использовании центральных 16 токенов:

$$\mathrm{MAE}(L) = 2.07, \qquad R^2(L) = 0.977.$$

Для красочности и цветового тона лучший результат дали четыре центральных токена:

$$\mathrm{MAE}(C) = 2.61, \qquad R^2(C) = 0.947,$$

$$\mathrm{MAE}(h) = 25.21^\circ, \qquad R^2(h) = 0.902.$$

9 Регрессия по глобальным KMeans-кластерам

9.1 Постановка

Независимая кластеризация каждого изображения не подходит для обучения общей регрессии, поскольку номера кластеров не согласованы между изображениями.

Например,

cluster 0 на первом изображении

не обязательно соответствует

cluster 0 на втором изображении.

Поэтому был обучен один глобальный MiniBatchKMeans.

Для исключения утечки информации KMeans обучался только на токенах train-изображений.

Число токенов для обучения KMeans:

$$395 \cdot 64 = 25280.$$

После обучения глобального KMeans каждому токену всех изображений назначалась кластерная метка.

Для каждого изображения и каждого кластера вычислялось среднее:

$$\overline{\boldsymbol{z}}_{n,k} = \frac{1}{N_{n,k}} \sum_{i:c_{n,i}=k} \boldsymbol{z}_{n,i}.$$

К среднему эмбеддингу добавлялась доля токенов этого кластера:

$$p_{n,k} = \frac{N_{n,k}}{64}.$$

Итоговый признаковый вектор имел размерность

$$3584 + 1 = 3585.$$

Для каждого кластера обучалась отдельная Ridge-регрессия.

Исследовались

$$K = 2, 3, 4.$$

9.2 Результаты при $K = 2$

Среднее число токенов на изображение:

- кластер 0: 18.39;
- кластер 1: 45.61.

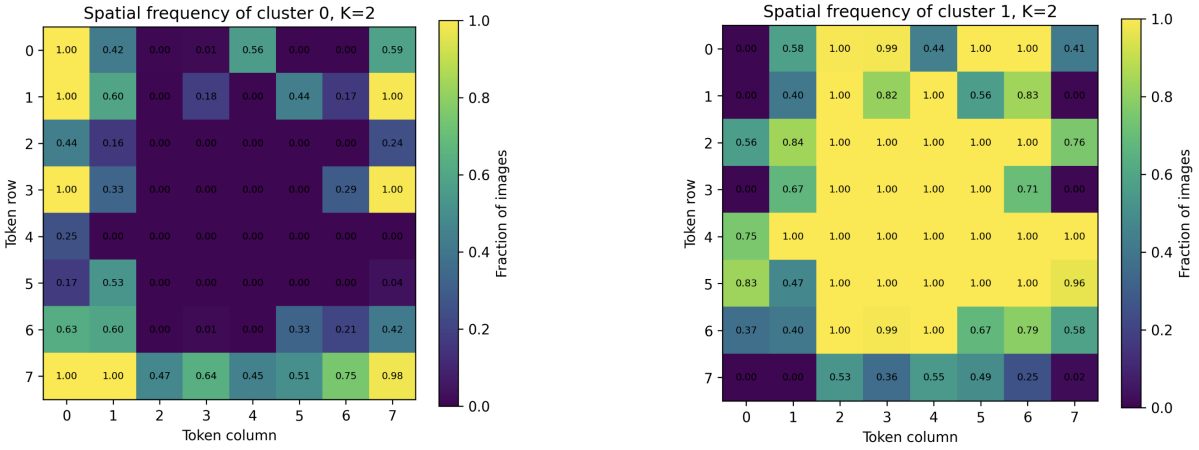
Table 4: Результаты кластерной регрессии при $K = 2$.

Кластер	Цель	Train MAE	Test MAE	Train R^2	Test R^2
0	L	1.467	2.230	0.988	0.971
0	C	2.084	3.196	0.976	0.925
0	h	28.169	39.908	0.870	0.807
1	L	1.506	2.189	0.988	0.973
1	C	1.975	2.721	0.978	0.952
1	h	21.940	29.514	0.910	0.877

Кластер 1 показывает лучшее качество для всех трёх компонентов.

9.3 Пространственная интерпретация кластеров при $K = 2$

Для каждой позиции сетки 8×8 была рассчитана доля изображений, в которых токен данной позиции принадлежал определённому кластеру.



(a) Частота принадлежности кластеру 0.

(b) Частота принадлежности кластеру 1.

Figure 8: Пространственные частоты кластеров при $K = 2$.

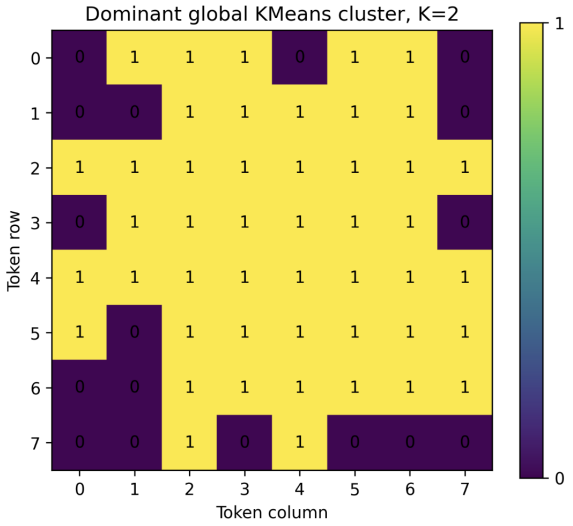


Figure 9: Доминирующий глобальный кластер в каждой позиции сетки 8×8.

Кластер 1 занимает преимущественно внутреннюю часть изображения, включая центральные позиции.

Кластер 0 чаще встречается:

- на краях изображения;
- в угловых позициях;
- в нижней строке сетки;
- в некоторых позициях верхней строки.

Таким образом, при $K = 2$ KMeans разделяет токены преимущественно на внутренние и краевые.

Лучшее качество кластера 1 согласуется с результатами регрессии по центральным токенам.

9.4 Результаты при $K = 3$

Table 5: Результаты кластерной регрессии при $K = 3$.

Кластер	Цель	Среднее число токенов	Train MAE	Test MAE	Train R^2	Test R^2
0	L	18.62	1.541	2.055	0.987	0.975
0	C	18.62	2.054	2.544	0.977	0.956
0	h	18.62	25.668	36.610	0.886	0.821
1	L	41.12	1.446	2.131	0.989	0.974
1	C	41.12	1.975	2.849	0.978	0.947
1	h	41.12	24.639	36.485	0.897	0.826
2	L	4.26	1.474	2.218	0.988	0.974
2	C	4.26	1.923	2.648	0.979	0.950
2	h	4.26	19.211	28.035	0.932	0.884

Кластер 0 показывает лучшие результаты для L и C:

$$\mathrm{MAE}(L) = 2.055, \qquad R^2(L) = 0.975,$$

$$\mathrm{MAE}(C) = 2.544, \qquad R^2(C) = 0.956.$$

Кластер 2 содержит в среднем только около четырёх токенов и показывает лучшее среди кластеров $K = 3$ качество для h.

9.5 Результаты при $K = 4$

Table 6: Результаты кластерной регрессии при $K = 4$.

Кластер	Цель	Среднее число токенов	Train MAE	Test MAE	Train R^2	Test R^2
0	L	35.76	1.408	2.209	0.989	0.973
0	C	35.76	1.879	2.742	0.980	0.950
0	h	35.76	24.193	36.682	0.901	0.833
1	L	4.27	1.503	2.230	0.987	0.973
1	C	4.27	1.949	2.716	0.979	0.949
1	h	4.27	19.025	26.361	0.930	0.895
2	L	7.89	2.902	4.780	0.874	0.743
2	C	7.89	3.238	4.921	0.900	0.797
2	h	7.89	39.591	58.266	0.746	0.607
3	L	16.07	1.488	2.245	0.988	0.969
3	C	16.07	2.053	2.695	0.977	0.951
3	h	16.07	25.554	34.533	0.887	0.826

Кластер 1 содержит в среднем

$$4.27$$

токена и показывает лучшее кластерное качество для цветового тона:

$$\mathrm{MAE}(h) = 26.36^\circ, \qquad R^2(h) = 0.895.$$

Кластер 2 отсутствует в 74 изображениях. В таких случаях для него использовался нулевой средний embedding-вектор.

Это приводит к заметному снижению качества и делает результаты данного кластера менее надёжными.

10 Сравнение способов представления изображения

Table 7: Лучшие тестовые результаты рассмотренных представлений.

Представление	L MAE	L R^2	C MAE	C R^2	h MAE	h R^2
Все 64 токена	2.20	0.971	3.35	0.915	49.99	0.748
Центральные 4	2.16	0.974	2.61	0.947	**25.21**	**0.902**
Центральные 16	2.07	0.977	3.11	0.931	35.77	0.832
Фоновые 48	2.36	0.969	3.37	0.911	53.24	0.721
$K = 3$, кластер 0	**2.05**	0.975	**2.54**	**0.956**	36.61	0.821
$K = 4$, кластер 1	2.23	0.973	2.72	0.949	26.36	0.895

Основные результаты:

- светлота L хорошо восстанавливается из большинства представлений;

- лучший результат для L и C получен для кластера 0 при $K = 3$;
- лучший результат для h получен при использовании четырёх центральных токенов;
- кластер 1 при $K = 4$, содержащий около четырёх токенов, почти достигает качества явно выбранной центральной области;
- фоновые токены показывают худшее качество для цветового тона;
- использование всех 64 токенов не даёт лучшего результата, несмотря на значительно большую размерность признаков.

11 Сравнение качества на обучающей и тестовой выборках

Для проверки переобучения во всех исправленных экспериментах рассматривались одновременно train- и test-метрики.

Для регрессии по всем токенам:

$$R^2_{\text{train}}(h) = 0.9998, \qquad R^2_{\text{test}}(h) = 0.748.$$

Разрыв составляет

$$0.9998 - 0.748 \approx 0.252.$$

Для кластера 1 при $K = 4$:

$$R^2_{\text{train}}(h) = 0.930, \qquad R^2_{\text{test}}(h) = 0.895.$$

Разрыв составляет только

$$0.930 - 0.895 = 0.035.$$

Table 8: Сравнение степени переобучения для цветового тона.

Представление	Train R^2	Test R^2	Разрыв
Все 64 токена	0.9998	0.748	0.252
Центральные 4 токена	0.967	0.902	0.065
$K = 4$, кластер 1	0.930	0.895	0.035

Таким образом, использование меньшего числа информативных признаков уменьшает переобучение.

Полное представление из 229376 признаков почти идеально запоминает обучающие данные, но хуже обобщается на новые изображения.

12 Проверка зануляющихся visual embeddings

Для каждого визуального токена вычислялась евклидова норма:

$$\|\boldsymbol{z}_i\|_2 = \sqrt{\sum_{j=1}^{3584} z_{i,j}^2}.$$

Для центрального цветового патча были рассмотрены четыре токена:

$$(3,3), \quad (3,4), \quad (4,3), \quad (4,4).$$

Полученные значения:

Table 9: Нормы центральных visual embeddings.

Позиция	$\|\boldsymbol{z}_i\|_2$
$(3,3)$	51.95
$(3,4)$	54.20
$(4,3)$	52.07
$(4,4)$	57.80

Минимальная норма среди рассмотренных visual tokens составила

$$\min_i \|\boldsymbol{z}_i\|_2 \approx 16.08.$$

Максимальная норма составляла приблизительно

$$58.60.$$

Полностью зануляющихся embedding-векторов обнаружено не было.

Центральные токены имеют нормы от 51.95 до 57.80, то есть не являются неактивными.

Более того, результаты регрессии по пространственным областям показывают, что именно центральные токены содержат наиболее полезную информацию для восстановления C и h.

13 Вывод

Проведённые эксперименты показали следующее.

- Visual tokens Qwen сохраняют пространственную структуру изображения.
- KMeans выделяет пространственно связанные области, однако количество кластеров не соответствует напрямую количеству цветов.
- Изменение фона влияет на распределение кластеров даже при неизменном центральном цветовом патче.
- Непосредственные графики значений эмбеддингов показывают, что токены различаются по значениям компонент и распределениям.
- FFT-анализ не дал интерпретируемого результата и был заменён анализом значений компонент эмбеддинга.

- Первоначальная регрессия по отдельным токенам показала наличие цветовой информации, но её постановка была методологически некорректной.
- В исправленной постановке одному изображению соответствует один объект, содержащий совокупность его visual embeddings.
- Регрессия по всем 64 токенам хорошо восстанавливает L и C, но сильно переобучается.
- Центральные токены содержат больше информации о центральном цветовом патче, чем фоновые.
- Четыре центральных токена дают лучший результат для C и h.
- Глобальная KMeans-кластеризация автоматически выделяет небольшие группы информативных токенов.
- При $K = 4$ кластер примерно из четырёх токенов восстанавливает цветовой тон почти так же хорошо, как явно выбранные центральные токены.
- Сравнение train- и test-метрик показывает, что компактные представления меньше переобучаются.
- Полностью зануляющихся visual embeddings не обнаружено.
- Центральный цветовой патч соответствует активным токенам с большими нормами.

Главный результат состоит в том, что цветовая информация представлена в visual embeddings Qwen неравномерно.

Наиболее информативны токены центральной области изображения. Использование только центральных токенов или автоматически выделенных кластеров позволяет уменьшить размерность признаков, снизить переобучение и сохранить высокое качество восстановления координат цвета.